

Beautiful Soup & Parser

Beautiful Soup

■ Beautiful Soup이란?

- 스크린 스크래핑(screen-scraping) 프로젝트를 위해 설계된 파이썬 라이브러리
- 구문 분석, 트리 탐색, 검색 및 수정을 위한 몇 가지 간단한 방법과 파이썬 관용구를 제공하며 문서를 분석하고 필요한 것을 추출하는 도구
- 들어오는 문서를 유니코드로 보내고 문서를 UTF-8로 자동 변환
- lxml 및 html5lib과 같은 파이썬 파서 라이브러리를 사용할 수 있음
 - 이를 이용하면 속도를 개선시키거나 호환성이 높은 응용프로그램을 만들 수 있음

■ 공식 사이트

- <https://www.crummy.com/software/BeautifulSoup/>
- <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>

Beautiful Soup

■ 파서 라이브러리

파서	사용법	장점	단점
파이썬의 html.parser	<code>BeautifulSoup(markup, "html.parser")</code>	• 보통 속도 • 파이썬 2.7.3, 3.2.2 이상 버전에서 호환됨	• 파이썬 2.7.3 또는 3.2.2 이전버전에서 호환되지 않음
lxml's HTML parser	<code>BeautifulSoup(markup, "lxml")</code>	• 매우 빠름 • 호환성	• 외부 C에 의존함
lxml's XML parser	<code>BeautifulSoup(markup, "lxml-xml")</code> <code>BeautifulSoup(markup, "xml")</code>	• 매우 빠름	• XML 파서만 지원 • 외부 C에 의존함
html5lib	<code>BeautifulSoup(markup, "html5lib")</code>	• 호환성이 높음 • 웹브라우저와 같은 방식으로 페이지 파싱 • 유효한 HTML5를 만듦	• 매우 느림

Beautiful Soup

■ Selector API

- BeautifulSoup은 가장 일반적으로 사용되는 CSS 선택자를 지원
- BeautifulSoup의 Selector API는 `select()`와 `select_one()`, `find()` 등
- `select()`와 `select_one()` 메서드만 알아도 원하는 요소를 찾기에 충분
- `soup.select("CSS 선택자")` : CSS 선택자에 해당하는 모든 요소를 반환
- `soup.select_one("CSS 선택자")` : CSS 선택자에 맞는 오직 첫 번째 태그 요소만 반환
- <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>

Beautiful Soup


■ CSS 선택자

■ CSS(Cascading Style Sheet)

- CSS는 문서의 콘텐츠와 레이아웃, 글꼴 및 시각적 요소들로 표현되는 문서의 외관(디자인)을 분리하기 위한 목적으로 만들어졌음

■ CSS 선택자

- CSS를 이용해서 HTML 문서에 시각적 요소를 부여할 때 문서 내의 어느 요소에 부여할지를 결정하기 위해 사용하는 것
- CSS 선택자(Selector)는 HTML 문서의 태그 이름, class 속성, id 속성 등을 이용해서 작성할 수 있음



Beautiful Soup

■ CSS 선택자

선택 방법	CSS Selector	예
태그	태그명	div
class	.클래스명	.product
id	#아이디	#content
태그 + class	태그.클래스	div.product
하위 요소	A B	.product .name
직계 자식	A > B	ul > li
여러 요소	A, B	h1, h2
속성	[속성]	[href]
속성값	[속성="값"]	[type="text"]
n번째 요소	:nth-child()	li:nth-child(2)

Beautiful Soup

■ 선택자 종류에 따른 Selector API

■ 태그 선택자 ("element")

- 태그 선택자는 일반적으로 스타일 정의하고 싶은 html 태그 이름을 사용
- 요소 안의 텍스트는 text, 태그이름은 name 그리고 태그의 속성들은 attrs를 이용해 조회

```
soup.select("h1")
```

■ 다중(그룹) 선택자 ("selector1, selector2, selectorN")

- 선택자를 ","(comma)로 분리하여 선언하면 여러 개 선택자 적용.
- 해당하는 모든 선택자의 요소를 찾기 때문에 select_one()아닌 select() 메서드를 이용

```
soup.select("h1, p")
```

Beautiful Soup

■ 선택자 종류에 따른 Selector API

■ 내포 선택자 ("ancestor descendant")

- 요소가 내포 관계가 있을 때 적용시키기 위한 선택자.
- 선택자와 선택자 사이를 공백으로 띄우고 나열

```
soup.select("div b")
```

■ 자식 선택자 ("parent > child")

- 선택자와 선택자 사이에 >를 입력하며 반드시 부모자식간의 관계에만 스타일이 적용되도록 함
- 두 단계 이상 건너뛴 관계에서는 자식 선택자가 작동하지 않음

```
soup.select("div > b")
```


Beautiful Soup

■ 선택자 종류에 따른 Selector API

■ 클래스(class) 선택자 (".class")

- HTML 문서에서 class 속성의 값과 일치하는 요소를 선택
- 선택자 이름 앞에 "."을 이용하여 선언.

```
soup.select("div.contents")
```

■ 아이디(id) 선택자 (" #id ")

- HTML 문서에서 id 속성의 값과 일치하는 요소를 선택
- id 선택자는 #으로 정의합니다.

```
soup.select_one("#subject")
```

■ 속성 선택자 [name="value"]

- 특정한 속성을 갖는 요소만 선택.
- 속성 선택자는 [와]사이에 속성의 이름과 값을 지정

```
soup.select_one("[id=subject]")
```