

빅데이터 분석 개요

이 경 미

목 차


- 4차산업혁명과 데이터 과학
- 빅데이터 이해와 활용
- 데이터 수집과 절차
- 데이터베이스
- 데이터 분석 및 과정 이해
- 기본 용어 및 개념
- 데이터 탐색에서 모델링까지

4차 산업혁명과 데이터 과학

- 4차 산업혁명의 이해
- 4차 산업혁명을 실현하는 데이터 과학

4차 산업혁명의 이해

■ 산업혁명의 흐름



출처: 미래창조과학부 블로그

4차 산업혁명의 이해

▪ 4차 산업혁명 시대의 특징



초연결
hyper-connectivity

- 사물인터넷(IoT)
- 5세대 통신 5G



초지능
hyper-intelligence

- 빅데이터(BigData)
- 인공지능(AI)



초융합
hyper-convergence

- 디지털 트랜스포메이션(DX)
- 로봇 프로세스 자동화(RPA)

4차 산업혁명의 이해

- 생산의 3 요소
 - 토지(자연)
 - 노동
 - 자본
- 데이터 시대 생산 3 요소
 - 플랫폼
 - 데이터
 - 인공지능

4차 산업혁명의 이해

4차 산업혁명 시대의 특징



초연결
hyper-connectivity

- 사물인터넷(IoT) : 언제나, 어디서나, 어느 것과도 연결
- 5세대 통신 5G : 최대 20Gbps, 일상 100Mbps 속도




그림 1-2 네트워크에 연결된 사물과 세계 인구수 비교(출처: CISCO, IBSG, HP)

표 1-1 5G의 특징

특징	설명
초고속	초광대역 무선통신(eMBB)enhanced Mobile BroadBand • 유선과 무선의 차이가 없는 대용량 및 고속의 데이터 이용 환경 제공 • 4G에 비해 최대 20배 더 빠른 20Gbps까지 구현 가능(일상적으로는 100Mbps 보장 목표) • 모바일로 8K 콘텐츠 송수신 가능
초연결	대규모 사물통신(mMTC)massive Machine Type Communication • 산업 또는 일반인에게 IoT 사용 환경 제공 • 현재보다 최대 500배 더 많은 기기와 고밀집 연결 가능 • 고에너지 효율 • 스마트폰의 인터넷, PC의 인터넷을 넘어 진정한 IoT 가능
초저지연	고신뢰/초저지연 통신(uRLLC)ultra-Reliable Low-Latency Communication • 최대 1ms까지의 낮은 지연성과 고안정성을 목표로 데이터 통신 서비스의 품질(QoS)을 제공

4차 산업혁명의 이해

4차 산업혁명 시대의 특징



초지능
hyper-intelligence

- 빅데이터(BigData) : 초지능의 원료
- 인공지능(AI) : 초지능을 제작
- ✓ Super intelligence*로 진화

*인공지능의 지능이 인간을 넘어서는 특이점을 통과하여 거의 모든 영역에서 인간의 인지 능력을 크게 능가 하는 경우




표 1-2 AI의 주요 기술 분야

분야	설명
추론	인간의 사고 능력을 모방하는 기술
지식 표현 및 언어 지능	사람이 사용하는 자연어 이해를 기반으로 사람과 상호작용하는 기술
청각 지능	음성, 음향, 음악을 분석, 인식, 합성, 검색하는 기술
시각 지능	사물의 위치, 종류, 움직임, 주변과의 관계 등 시각 이해를 기반으로 지능화된 기능을 제공하는 기술
복합 지능	시공간, 촉각, 후각 등 주변의 상황을 인지 및 예측하고 상황에 적합한 대응을 제공하는 기술
지능형 에이전트	개인 비서, 챗봇 등 가상 환경에 위치하여 특별한 응용 프로그램을 다루는 사용자를 도울 목적으로 반복적인 작업을 자동화시켜 주는 기술
인간과 기계의 협업	인간의 감성이나 의도를 이해하기 위해 인간의 뇌 활동에 기계가 연동되어 작동하는 기술
AI 기반 하드웨어	초고속 지능 정보 처리를 구현하게 지원하는 하드웨어 기술

그림 1-3 온라인 뉴스의 빅데이터 키워드 분석 - 분야별 현황과 시사점

4차 산업혁명의 이해

4차 산업혁명 시대의 특징



초융합
hyper-convergence

- 디지털 트랜스포메이션(DX)
- 로봇 프로세스 자동화(RPA)

DX

- 디지털 기술을 활용하여 기존 산업의 운영 및 생산의 효율성과 경쟁력을 높이는 프로세스의 변화
- 디지털 기술을 활용하여 다양한 산업 분야에서 지속적인 혁신을 추진, 특히 제조업에 주목
- 기존 비즈니스 모델 뿐만 아니라 고객의 경험을 변화시키고 추가 수익 흐름을 창출

RPA




그림 1-4 임금 지급 업무에 RPA를 도입한 예

4차 산업혁명을 실현하는 데이터 과학

■ 데이터 과학(data science)

- 비즈니스에 대한 의미있는 인사이트를 추출하기 위한 데이터 연구로서, 수학, 통계, 인공지능 및 컴퓨터 공학 분야의 원칙과 사례를 결합하여 대량의 데이터를 분석하는 종합적인 접근 방식 (AWS)
- 데이터 마이닝(Data Mining)과 유사하게 정형, 비정형 형태를 포함한 다양한 데이터로부터 지식과 인사이트를 추출하는 과정에서 과학적 방법론, 프로세스, 알고리즘, 시스템을 동원하는 융합 분야 (Wikipedia)



4차 산업혁명을 실현하는 데이터 과학

■ 데이터 과학과 { IoT + BigData + AI }

- IoT를 구성하는 센서와 기기의 노드 : 감각 및 행동 기관
- 인터넷/5G : 인지된 자극과 명령을 전달하는 신경계
- AI : 인지된 자극을 처리하고 분석하여 명령을 내리는 두뇌




그림 1-5 IoT와 빅데이터, AI 결합의 의미




그림 1-6 {IoT + 빅데이터 + AI}와
데이터 과학의 완전체 개념도

4차 산업혁명 서비스 사례

■ 자율주행차와 커넥티드 카

– 자율주행차

- 인지-판단-제어라는 3가지 단계로 동작
- 도로 환경에서 빅데이터를 수집하여 상황을 인지하고 판단한 뒤 신속하게 제어
- 자율주행차는 운전자와 차량의 역할 비중에 따라 5가지 레벨로 구분

– 자율주행차와 커넥티드 카에 필요한 핵심 기반 기술

- 주변 환경의 빅데이터 수집 및 분석
- 차량 부품의 빅데이터 수집 및 진단
- 차량 제어, 고속 무선 통신

표 1-3 자율주행자의 5가지 레벨

레벨	설명
레벨 0	자동화 기능이 미적용된 상태
레벨 1	운전자 보조주행: 운전자가 속도 또는 방향을 통제
레벨 2(현재)	부분적 자율주행: 차간 거리 및 속도 유지 등이 가능하지만 운전자가 주행에 적극 개입해야 하는 상태
레벨 3	조건부 자율주행: 자율주행 시스템을 운행하지만 비상시 몇 초 안에 운전자가 개입해야 하는 상태
레벨 4	고수준 자율주행: 비상시 차량이 일정 시간은 자체 대응하는 상태로 운전자가 차량 내에서 책을 읽어도 되는 수준
레벨 5	완전 자율주행: 어떠한 도로 환경에서도 무인 자율주행이 가능한 상태

4차 산업혁명 서비스 사례

■ 자율주행차와 커넥티드 카

– 커넥티드 카

- 정보통신기술과 자동차 연결 : 양방향 인터넷, 모바일 서비스 가능




그림 1-7 커넥티드 카의 운전자 맞춤 서비스 개념도(출처: ETRI IoT 추진 계획)

4차 산업혁명 서비스 사례

■ 스마트 시티

- 도시 구성원과 시설 기관들이 네트워킹이 가능하도록 인터넷과 IoT 등의 통신 인프라가 갖춰진 것
- 빅데이터 및 AI와 융합하여 보다 편리하고 안전한 생활 및 업무 환경을 구현하는 4차 산업 혁명 시대의 진화된 도시
- 스마트 시티에 필요한 핵심 기반 기술
 - IoT와 AI, 빅데이터 분석, AR/VR/MR, 건강/교통/교육/기기제어 등의 요소 기술

표 1-4 스마트 시티의 구성 요소

구성 요소	기능
스마트 홈/사무실	• 주거, 사무실, 학교, 편의시설 등이 상호 유기적으로 연결되어 사용자 요구를 예측해서 해결 • 개인별 편의성 극대화 • 재택근무 등 업무 환경의 제한 완화
스마트 시설 관리	• 발전, 교량, 환경 등 사회 기간 시설의 실시간 관제를 통해 에너지 절약 및 운영 효율화
스마트 교통	• 교통 시설이나 도로 상황의 실시간 지능형 관제를 통해 시간 단축 및 운영 효율화 • 개인별 이동 상황에 따른 맞춤형 교통 편의 제공
스마트 교육	• 학생별 학습 수준에 따라 맞춤형 교육을 제공하는 AI 기반의 튜터링 시스템 보급
스마트 치안	• 빅데이터 분석을 기반으로 범죄, 테러, 사고 등의 징후 예측 및 예방 • 유사시 효과적인 구조 조치를 통해 안전한 생활 환경 구축
스마트 환경	• 신재생 및 청정 에너지 기술, 생활 환경의 위생 상태 측정 및 관리, 자원 재활용, 환경오염의 측정/예방/처리가 융합되어 쾌적하고 청결하며 안전한 생활 환경 구축
스마트 문화/여가	• 문화, 콘텐츠, 스포츠와 VR, AR, MR 기술이 융합하여 개인 맞춤형의 건강, 재미, 지식을 제공하는 복합적 오락, 운동, 문화 체험 환경 제공

4차 산업혁명 서비스 사례

■ 스마트 헬스케어

- 개인의 건강에 대한 의료 정보, 기기, 시스템, 플랫폼을 다루는 산업 분야
- 건강 관련 서비스와 의료 IT가 융합된 종합 의료 서비스
- 스마트 헬스 케어에 필요한 핵심 기반 기술
 - 종합 건강 정보 빅데이터 구축, 분야별 지식베이스 구축
 - 건강 빅데이터에 대한 실시간 수집 및 분석, 진단 및 처방용 AI스마트시티의 개념

표 1-5 헬스 케어 서비스와 ICT 융합의 발전 과정

구분	Tele-헬스 케어	e-헬스 케어	u-헬스 케어	스마트 헬스 케어
시기	1999년대 중반	2000년대 초반	2000년대 후반	2010년 이후
핵심 서비스	병원 내 치료	치료, 의료 정보 제공	e-헬스 케어 + 원격 의료, 만성 질환자 관리로 질병 예방	u-헬스 케어 + 운동 및 식량 등의 건강 생활 관리, 복지, 안전
공급자	병원	병원	병원, ICT 기업	병원, ICT 기업, 보험사, 헬스케어 서비스 기업
주요 이용자	의료인	의료인, 환자	의료인, 환자, 일반인	의료인, 환자, 일반인
핵심 ICT 기술		초고속 인터넷	무선 인터넷	스마트 기기, 앱, AI, 빅데이터

빅데이터 이해와 활용

- 빅데이터 등장 배경
- 빅데이터 개념
- 빅데이터 특징
- 빅데이터 가치
- 빅데이터 역할
- 빅데이터 활용
- 빅데이터 처리 과정

빅데이터 등장 배경

■ 빅데이터(Big Data)

존 마시(John R. Mashey) : 실리콘 그래픽스 인터내셔널(SGI)의 수석 과학자
1998.04.25, '**Big Data** ... and the Next Wave of InfraStress' 보고서



〈데이터 폭발을 예측한 존 마시의 1998년 보고서 첫 장〉



Big Data ... and the Next Wave of *InfraStress*

John R. Mashey
Chief Scientist, SGI

Technology Waves:
NOT technology for technology's sake
IT'S WHAT YOU DO WITH IT
But if you don't understand the trends
IT'S WHAT IT WILL DO TO YOU

Uh-oh!  OK!

4/25/98 page 1



Big Data **And The Next Wave of *InfraStress***

- Big data:** storage growing bigger faster
DRAM: 1.6X/year (4X/3 years) continues
Disk density:
1.3X/year CAGR: historical trendline
1.6X/year since ~1990
2.0X/year leap ~1998/1999
- Net** continues raising user expectations
More data (image, graphics, models)
(Some) more difficult data (audio, video)
Pressure on net, especially last mile
=> Explosion of WIDELY-accessible data
Create, understand, store, move ... or else ...
Drown in Wave of *Infrastructure Stress*

General references: John Hennessy, David A Patterson, Computer Architecture: A Quantitative Approach, Second Edition, Morgan Kaufmann, San Francisco, 1996, ISBN 1-55860-329-8.
Also, Computer Organization and Design, Morgan Kaufmann, San Francisco, 1994, ISBN 1-55860-281-X.
Also, thanks to Glenn Stettler of SGI, "Disk Drive Futures", 1/20/99.


4/25/98 page 2

출처: http://static.usenix.org/event/usenix99/invited_talks/mashey.pdf

빅데이터 등장 배경

■ 빅데이터(Big Data)


2000년대 초반부터는 디지털 미디어 저장용량의 폭발적 증가로 2007년에는 디지털이 전체 저장장치의 대부분을 차지하게 된다는 것



빅데이터 등장 배경

■ 빅데이터의 출현


- 기술 발전에 따른 데이터 저장, 처리 비용의 감소
- 실시간 서비스, SNS 서비스 등 디지털 정보량의 기하급수적 증가
- 기존의 데이터 저장, 관리, 분석 기법의 한계



빅데이터 등장 배경

■ 제타바이트 시대

정보 통신 기술 발전에 따른 데이터의 변화 방향



데이터 단위

- 1TB = 1,024GB
- 1PB = 1,024TB
- 1EB = 1,024PB
- 1ZB = 1,024EB
- 1YB = 1,024ZB

사진1장 = 3MB

사진 1000장 = 3,000MB = 3GB

1PB : 100GB 용량 핸드폰 10,000대 분량




빅데이터 등장 배경

■ 제타바이트 시대

- Instagram
 - 전 세계 약 23억 5천만명 사용자
 - 매일 9,500만 개 사진과 동영상 공유
 - 분당 65,972개 공유
 - 사용자 하루 평균 53분을 사용
- 온라인, 모바일 검색
 - Google 매 분 900만 건 검색 발생
 - ✓ 매 분 5.7M 검색
 - 웹 트래픽의 최대 70%가 모바일 장치에서
 - 81% 사람들의 구매를 위해 온라인 검색
- YouTube
 - 매달 20억 명이 로그인
 - 매일 약 50억 개 동영상 시청
 - 매일 5B 분량의 비디오 시청
- Amazon
 - 1초마다 4,722 달러 소비
 - 1분마다 600만 명 이상이 쇼핑

What Happens in an Internet Minute



출처 : <https://localiq.com/blog/what-happens-in-an-internet-minute/>

빅데이터 개념

■ 정의

“일반적인 데이터베이스 소프트웨어로 저장, 관리, 분석할 수 있는 범위를 초과하는 규모의 데이터”(Mckinsey, 2011)

“향상된 시사점과 더 나은 의사결정을 위해 사용되는 것으로 비용 효율이 높고 혁신적이며 대용량 고속 및 다양성을 가지는 정보자산”(Gartner)

“다양한 종류의 대규모 데이터로부터 저렴한 비용으로 가치를 추출하고 데이터의 초고속 수집, 발굴, 분석을 지원하도록 고안된 차세대 기술 및 아키텍처”(IDC, 2011)

“기존 데이터베이스 관리도구의 능력을 넘어서는 대량(수십 테라바이트)의 **정형** 또는 심지어 데이터베이스 형태가 아닌 **비정형**의 데이터 집합조차 포함한 데이터로부터 가치를 추출하고 결과를 분석하는 기술”(위키피디아)

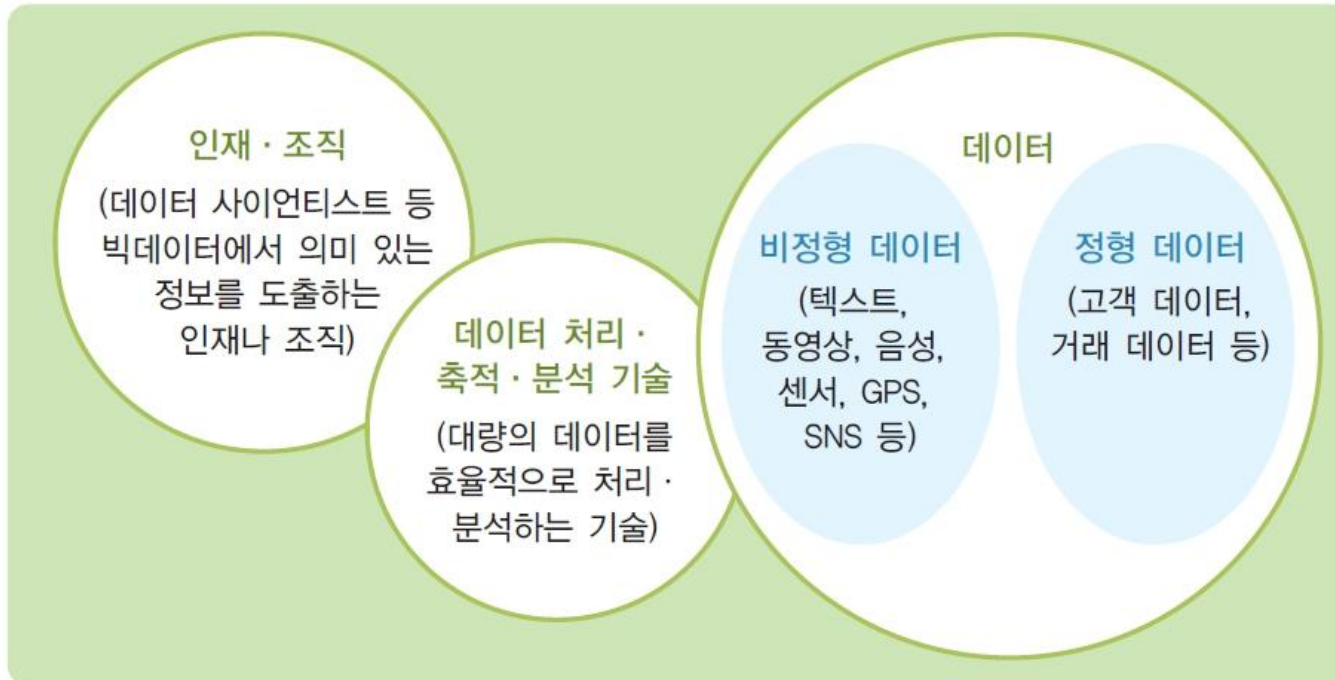
“대용량 데이터를 활용 및 분석하여 가치 있는 정보를 추출하고 생성된 지식을 바탕으로 능동적으로 대응하거나 변화를 예측하기 위한 정보화 기술”(국가전략위원회)

*Very Large DB, Extremely Large DB,
Extreme Data, Total Data*




빅데이터 개념

- 광의적 정의




빅데이터 특징

- 5V




빅데이터 특징

- 6V



빅데이터 특징

- 7V



빅데이터 특징

- 빅데이터가 만들어내는 변화
 - 처리 방식 측면

구분	이전의 데이터 처리 방식	빅데이터 처리 방식
데이터 트래픽	테라바이트 수준	- 페타바이트 수준: 최소 100테라바이트 이상 - 정보의 장기간 수집 및 분석 - 방대한 처리량
데이터 유형	정형 데이터 중심	- 비정형 데이터 비중이 높음: SNS 데이터, 로그 파일, 클릭스트림 데이터, 콜센터 로그 통신, CDR 로그 등 - 처리 복잡성 증대
프로세스 및 기술	- 단순한 프로세스 및 기술 - 정형화된 처리 및 분석 결과 - 원인 및 결과 규명 중심	- 다양한 데이터 소스와 복잡한 로직 처리 - 처리 복잡도가 높아 분산 처리 기술 필요 - 새롭고 다양한 처리 방법 필요: 정의된 데이터 모델/상관관계/절차 등이 없음 - 상관관계 규명 중심 - 하둡, NoSQL 등 개방형 소프트웨어 사용

빅데이터 특징


- 빅데이터가 만들어내는 변화
 - 분석 환경 측면

요소	과거의 데이터 분석 환경	현재의 빅데이터 분석 환경
데이터	정형화된 수치 중심의 자료	- 비정형의 다양한 데이터 - 예: 문자 데이터(SMS, 검색어), 영상 데이터(CCTV, 동영상), 위치 데이터 등
하드웨어	- 고가의 저장 장치 - 데이터베이스 - 대규모 데이터웨어하우스	클라우드 컴퓨팅: 비용 대비 효율성 증대
소프트웨어 분석 방법	- 관계형 데이터베이스: RDBMS - 통계 패키지: SAS, SPSS - 데이터 마이닝 - 머신러닝 - 지식 발견	- 오픈 소스 형태의 무료 소프트웨어 - 오픈 소스 통계 솔루션: R - 텍스트 마이닝 - 오피니언 마이닝 - 감성 분석

빅데이터 가치

■ 혁신과 창조의 도구

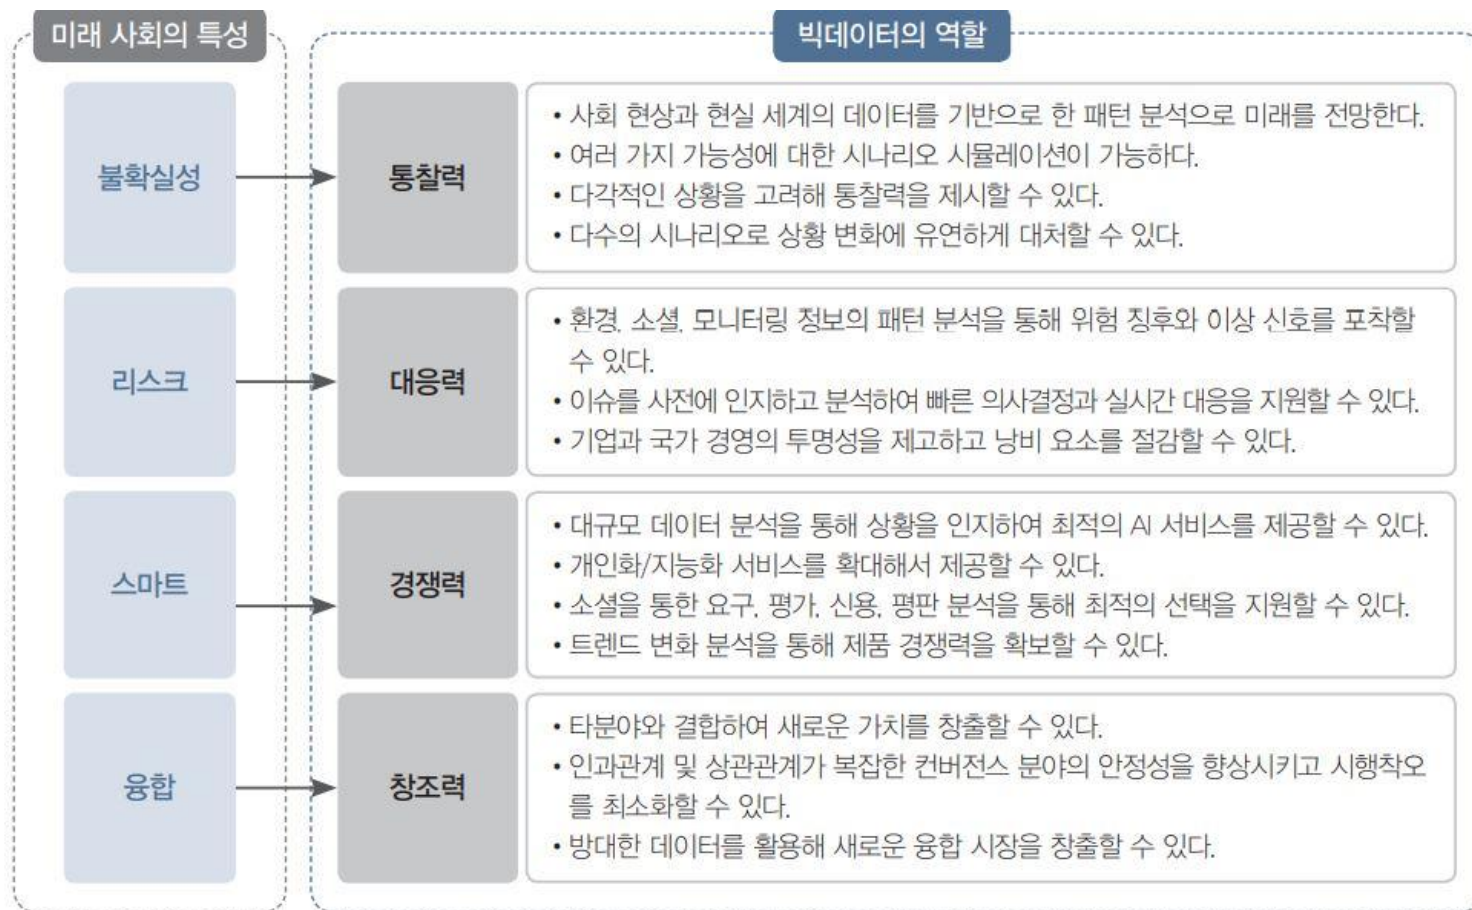
- 정보의 투명성
- 실험을 통한 소비자의 요구발견, 트렌드 예측, 성과 관리
- 비즈니스 효율화, 개인화, 미래 예측력을 통한 혁신 제공
 - 소비자 맞춤 비즈니스를 위한 고객 세분화
 - 자동화된 알고리즘을 통한 의사결정
- 새로운 패러다임으로 변화
 - 새로운 비즈니스 모델, 상품, 서비스와 혁신
 - 플랫폼과 에코시스템



Big Data = "21세기 석유"



빅데이터 역할



빅데이터 활용

산업	빅데이터 후
제조업	설비 이상 감지, 생산성 향상, 원가 절감, 부적합(불량) 감지, 안전 사고 예방 등
금융 및 보험	사기 및 부정행위 탐지, 고객맞춤형 서비스 개발, 고객세분화, 리스크 최소화 등
유통 및 소매	물류 비용 최소화, 상품 진열 최적화, 재고관리 최적화 등
의료 및 제약	환자 진단, 영상 판독, 신약 개발 등
에너지	설비 이상 감지, 환경오염물질 배출 최소화, 발전량 예측, 전력수요예측, 안전사고 예방 등
통신	네트워크 최적화, 고객 이탈률 분석, 신규 서비스 개발 등
교육	학습 능력 향상, 학생 수준별 맞춤 수업 제공 등
인터넷 및 게임	타킷 광고, 고객 맞춤형 서비스 개발, 고객 세분화, 고객 이탈률 최소화, 부정행위 탐지 등
정부	CCTV설치위치 선정, 범죄예방, 교통량 최적화, 전기차 충전소 설치 위치 선정 등

빅데이터 처리 과정



데이터 수집

- 데이터 정의
- 데이터 분류
- 분석을 위한 데이터 유형

데이터(data)

- ‘datum’이라는 단어에서 유래
 - 라틴어 ‘주다(to give)’라는 뜻의 dare의 과거분사형
 - 주어진 것

데이터(data)

정의

- 가치판단의 근거가 될 수 있는 것
- 현실 세계로부터의 단순한 관찰이나 측정을 통해 수집된 사실이나 값
- 대상물 또는 상황
- 원자료(raw data) : 가공되지 않은 상태
- 분석의 원자재

SQ1) 귀하 본인 또는 귀하의 가족 중에 OO 회사 또는 조사회사, 광고회사, 언론사 등에 근무하시는 분이 계십니까?
1. 있다 → 조사 종료 2. 없다

SQ2) 귀하의 연세는 올해 만으로 어떻게 되십니까? _____ 세
1. 만 18세 이하 → 조사 종료 06. 만 40세 ~ 44세
2. 만 19세 ~ 24세 07. 만 45세 ~ 49세
3. 만 25세 ~ 29세 08. 만 50세 ~ 54세
4. 만 30세 ~ 34세 09. 만 55세 ~ 59세
5. 만 35세 ~ 39세 10. 만 60세 이상 → 조사 종료

SQ3) 귀하의 성별은 무엇입니까?
1. 남성 2. 여성

SQ4) 귀하의 직업은 무엇입니까?
1. 농업, 어업, 임업 (가족종사자 포함)
2. 자영업 (종업원 9사람 이하의 소규모장사 및 가족종사자, 택시기사)
3. 판매/서비스직 (상점점원, 세일즈맨 등)
4. 기능/숙련공 (운전자, 선반, 목공 등 숙련공)
5. 일반작업직 (토목관계의 현장작업, 수위)
6. 사무/기술직 (일반회사 사무직, 기술직, 초/중/고 교사)
7. 경영/관리직 (5급 이상의 고급공무원, 교장, 기업체 부장이상)
8. 전문/자유직 (대학교수, 의사, 변호사, 예술가)
9. 가정주부 (주로 가사에만 종사하는 부인)
10. 학생
11. 무직
12. 기타

SQ5) 귀하의 혼인상태는 어떻게 되십니까?
1. 미혼 2. 기혼 3. 이혼/별거/사별

데이터 (data)

- Dataset

- 관찰대상으로부터 속성들을 측정한 자료들의 모임

예. 2020년 인구주택총조사 중 일부


ID	성별	나이	가구주와의 관계	학력	출생아 수
1	여자	68	가구주의 배우자	초등학교	3
2	여자	29	가구주의 배우자	초등학교	0
3	여자	7	자녀	초등학교	결측
4	여자	3	자녀	안 받았음	결측
5	남자	26	자녀	중학교	결측
6	여자	52	가구주의 배우자	초등학교	2
7	여자	62	가구주의 배우자	고등학교	1
8	여자	10	자녀	초등학교	결측
9	남자	58	가구주	중학교	결측

-행 : 관측값(개체)

열 : 속성, 변수(측정, 자료)

데이터(data)

- 변수



데이터 분류

- 일반적인 데이터 특징에 따른 분류

- 존재론적 특징

- 데이터가 가지고 있는 존재적 특징
 - 정성적 데이터 vs 정량적 데이터

- 목적론적 특징

- 하나의 서비스 혹은 활용(데이터 분석)을 위해 데이터가 존재하고 있다는 인식에서 출발
 - 인식의 주체가 데이터에서 목적에 맞는 특징을 찾아냄

데이터 분류

- 존재론적 특징에 따른 분류
 - 데이터가 가지고 있는 존재적 특징

구분	정성적 데이터 (qualitative data)	정량적 데이터 (quantitative data)
형태	비정형 데이터	정형, 반정형 데이터
특징	객체 하나에 함축된 정보를 가짐	여러 속성이 모여 객체를 이룸
구성	언어, 문자	수치, 도형, 기호
저장형태	파일, 웹	데이터베이스, 스프레드시트
소스	외부 시스템(소셜데이터)	내부 시스템(RDBMS, Legacy)
예	SNS의 글, 보고서 내용 등 "환율이 내리고 있어 올해 목표한 수출 목표의 조기 달성이 가능해 보인다."	몸무게, 온도, 풍속, 이름, 나이, 주소, 성별 등

데이터 분류

▪ 수집 활동에 따른 분류

- 수집 활동에서 일어나는 모든 과정은 데이터를 재생산하는 과정
 - 원천 데이터를 탐색, 수집, 정제, 저장하는 과정을 거쳐 새로운 데이터를 생산
- 원본 데이터 vs 재생산 데이터

구분	가역적 데이터	비가역적 데이터
환원가능성	가능	불가능
의존성	원본 데이터에 의존적	원본 데이터에 독립적
원본 데이터와의 관계	1:1 관계	1:N 혹은 N:1
처리 과정	탐색	병합
활용 분야	데이터 웨어하우징, 로그 수집	소셜 분석, 텍스트 마이닝

데이터 분류

▪ 수집 데이터 형태에 따른 분류

구분	내용
정형 데이터 (structured data)	• 일반적으로 관계형 데이터베이스에 저장되는 스프레드시트 형 데이터 • 데이터 스키마와 실제 정보를 가지는 파일로 구성 • RDB, 엑셀, CSV 파일
반정형 데이터 (semi-structured data)	• 데이터 내부에 정형데이터의 스키마에 해당되는 메타데이터를 가짐 • 일반적으로 파일 형태로 저장 • HTML, XML, JSON
비정형 데이터 (unstructured data)	• 데이터세트가 아닌 하나의 데이터가 수집 데이터로 객체화 • SNS, 텍스트 데이터, 이미지, 동영상, 음성 등의 데이터

데이터 분류

▪ 수집 데이터 형태에 따른 분류


– 정형데이터

• 특징

- ✓ 관계형 데이터베이스 시스템의 테이블과 같이 고정된 컬럼에 저장되는 데이터와 파일
- ✓ 지정된 행과 열에 의해 데이터의 속성이 구별되는 스프레드 시트 형태의 데이터
- ✓ 데이터의 스키마 지원

• 데이터 탐색

- ✓ 테이블 탐색, 컬럼 구조 탐색, 로우 탐색 순으로 정형화되어 있음



데이터 분류

- 수집 데이터 형태에 따른 분류
 - 정형데이터
 - 형태

```
select COLUMN1, COLUMN2...from TABLE where CONDITION
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa

RDBMS의 테이블들(단일테이블 혹은 조인한 테이블 포함)
스프레드 시트

출처: <http://www.dbguide.net/>

데이터 분류

- 수집 데이터 형태에 따른 분류
 - 정형데이터
 - 예. 서울시 시간대별 대기질 데이터

	A	B	C	D	E	F	G	H
5	날짜	측정소명	미세먼지	초미세먼지	오존	이산화질소	일산화탄소	아황산가스
6	2022-07-29 01:00	서대문구	27	17	0.027	0.012	0.5	0.003
7	2022-07-29 02:00	서대문구	12	10	0.025	0.005	0.4	0.002
8	2022-07-29 03:00	서대문구	12	8	0.023	0.005	0.4	0.002
9	2022-07-29 04:00	서대문구	14	8	0.018	0.006	0.4	0.002
10	2022-07-29 05:00	서대문구	16	8	0.016	0.006	0.4	0.002
11	2022-07-29 06:00	서대문구	15	10	0.015	0.008	0.4	0.002
12	2022-07-29 07:00	서대문구	7	8	0.014	0.010	0.4	0.002
13	2022-07-29 08:00	서대문구	14	10	0.016	0.011	0.4	0.002
14	2022-07-29 09:00	서대문구	17	7	0.020	0.011	0.4	0.002
15	2022-07-29 10:00	서대문구	18	12	0.027	0.012	0.4	0.002
16	2022-07-29 11:00	서대문구	23	11	0.036	0.009	0.4	0.003
17	2022-07-29 12:00	서대문구	18	9	0.043	0.008	0.4	0.002
18	2022-07-29 13:00	서대문구	14	9	0.056	0.010	0.4	0.002
19	2022-07-29 14:00	서대문구	18	9	0.054	0.008	0.4	0.002
20	2022-07-29 15:00	서대문구	18	13	0.062	0.007	0.3	0.002
21	2022-07-29 16:00	서대문구	26	12	0.066	0.015	0.4	0.002

데이터 분류

- 수집 데이터 형태에 따른 분류

- 반정형데이터

- 특징

- ✓ 데이터 내부에 정형데이터의 스키마에 해당되는 **메타데이터**를 갖고 있음
 - ✓ 파일 형태로 저장

- 데이터 탐색

- ✓ 데이터 내부에 데이터 구조에 대한 메타정보를 갖고 있으므로 어떤 형태를 가진 데이터인지 파악하는 것이 필요
 - ✓ 데이터 내부에 있는 규칙성을 파악해 데이터를 파싱할 수 있는 파싱 규칙을 적용함

데이터 분류

- 수집 데이터 형태에 따른 분류

- 반정형데이터

- 형태

```
[{ "Sepal.Length" : 6.8,  
  "Sepal.Width" : 3.2,  
  "Petal.Length" : 5.9,  
  "Petal.Width" : 2.3,  
  "Species" : "virginica" },  
{ "Sepal.Length" : 6.7,  
  "Sepal.Width" : 3.3,  
  "Petal.Length" : 5.7,  
  "Petal.Width" : 2.5,  
  "Species" : "virginica" }]
```

- 예.

- ✓ URL 형태로 존재 : HTML
 - ✓ 오픈 API 형태로 제공 : XML, JSON
 - ✓ 로그 형태 : 웹로그, IoT에서 제공하는 센서데이터

데이터 분류

- 수집 데이터 형태에 따른 분류
 - 반정형데이터
 - 예. 공공데이터포털(data.go.kr)의 오픈API

오픈 API (9,265건)

농축수산 | 자치행정기관 [미리보기](#)

XML **JSON** 부산광역시_119 구조 반려동물 정보

119신고 포획한 동물의 발견 장소 및 인수인계 정보

제공기관 부산광역시 | 수정일 2022-07-29 | 조회수 2143 | 활용신청 72 | 키워드 입양,개,분실,구조정보,동물종류 [활용신청](#)

JSON 형태

산업고용 | 공공기관 | 국가중점 [미리보기](#)

XML **JSON** 소상공인시장진흥공단_상가(상권)정보

소상공인 상권정보 상가업소 데이터

제공기관 소상공인시장진흥공단 | 수정일 2022-07-29

문화관광 | 자치행정기관

XML 제주특별자치도 서귀포시_서귀포시 생활지

서귀포시 생활플랫폼 연습실 예약 현황 정보와 관련한 번호, 예

제공기관 제주특별자치도 서귀포시 | 수정일 2022-07-29

공공행정 | 자치행정기관

XML 제주특별자치도 서귀포시_서귀포시 행정자

서귀포시 행정자료실 도서 목록의 도서명, 작가명, 출판사, 도서

제공기관 제주특별자치도 서귀포시 | 수정일 2022-07-29

```
"header": {
  "title": "The JSON example",
  "descriptionText": "This is some title text."
},
"content": {
  "title": "The content example text",
  "elements": [
    {
      "title": "The first element",
      "mainText": "First element main text",
      "additionalText": "First element additional text"
    },
    {
      "title": "The second element",
      "mainText": "Second element main text",
      "additionalText": "Second element additional text"
    }
  ]
}
```

데이터 분류

▪ 수집 데이터 형태에 따른 분류

– 비정형데이터

• 특징

- ✓ 데이터 세트가 아닌 하나의 데이터가 수집 데이터로 객체화되어 있음
- ✓ 언어 분석이 가능한 텍스트 데이터
- ✓ 이미지, 동영상 같은 멀티미디어 데이터
- ✓ 웹에 존재하는 데이터의 경우 html 형태로 존재하여 반정형 데이터로 구분할 수도 있으나 특정한 경우 텍스트 마이닝을 통해 데이터를 수집하는 경우도 존재하므로 명확한 구분은 없음

• 데이터 탐색

- ✓ 이진 파일 형태 : 동영상, 이미지
 - » 데이터 종류별 응용SW를 이용하여 탐색
 - » 동영상은 동영상 플레이어
- ✓ 스크립트 파일 형태 : 소셜 데이터의 텍스트
 - » 데이터를 파싱해 처리

데이터 분류

- 수집 데이터 형태에 따른 분류
 - 데이터의 잠재적 가치

형태	특징	난이도
정형데이터	• 내부데이터의 특성상 현실적 가치의 한계로 활용 측면에서 잠재적 가치가 상대적으로 낮음	하
반정형데이터	• 데이터의 제공자가 선별해 제공하는 데이터로 잠재적 가치는 정형 데이터 보다 높음	중
비정형데이터	• 수집 주체에 의해 데이터에 대한 분석이 선행되므로 목적론적 데이터 특징이 가장 잘 나타나는 데이터 • 수집이 가능하면 수집 주체에게는 가장 높은 잠재적 가치를 제공	상

데이터 분류

▪ 수집 데이터 위치에 따른 분류

위치	원천데이터	종류
내부 데이터	서비스 시스템	ERP, CRM, KMS, 포털, 원장정보시스템, 인증/과금 시스템, 거래시스템 등
	네트워크 및 서버 장비	백본, 방화벽, 스위치, IPS, IDS 서버 장비 로그 등
	마케팅 데이터	VOC 접수 데이터, 고객 포털 시스템 등
외부 데이터	소셜 데이터	제품 리뷰 커뮤니티, 고객 포털 시스템 등
	특정 기관 데이터	정책 데이터, 토론 사이트
	M2M 데이터	센서 데이터, 장비 발생 로그
	LOD(Linked Open Data)	정부 공개 경제 의료, 지역 정보 데이터 공공 정책, 과학, 교육, 기술 데이터 산업, 역사, 환경, 경제, 과학, 통계 등 공공 데이터

데이터 분류

▪ 수집 데이터 위치에 따른 분류

– 수집 난이도

위치	특징	난이도
내부	• 소스데이터 담당자와 의사소통이 원활하기 때문에 수집 난이도가 외부데이터에 비해 낮음	하
외부	• 소스데이터 담당자와 의사소통이 어려워 수집 난이도가 높음	상

– 데이터 처리 아키텍처

위치	특징	난이도
내부	• 대부분 정형데이터이므로 일반적인 CRUD 처리 아키텍처와 같은 구성이 가능	하
외부	• 비정형, 반정형 데이터 형태로 일반적인 아키텍처 구성에 반정형, 비정형 데이터를 처리할 수 있는 아키텍처를 추가해야 함	상

데이터 분류

- 수집 데이터 위치에 따른 분류
 - 데이터의 잠재적 가치

위치	특징	난이도
내부	• 내부 데이터의 특성과 현실적 가치의 한계상 활용 측면에서 잠재적 가치는 상대적으로 낮음	보통
외부	• 데이터의 제공자가 선별해 제공하는 데이터나 수집주체에 대한 분석이 이루어진 후 수집을 하는 데이터이기 때문에 데이터의 목적론적 특징이 가장 잘 나타나는 데이터 • 내부 데이터와 비교할 경우 상대적으로 잠재적 가치가 높음	높음

데이터 분류

▪ 분석을 위한 데이터 유형


구분	내용
범주형 데이터	정해진 유형이나 순서로 구분되는 데이터 명목형 : 분류를 목적으로 하는 데이터(크기 비교 불가능) 순서형 : 대, 중, 소와 같이 값을 순서로 분류할 수 있는
숫자형 데이터	- 데이터 자체가 숫자로 표현 - 데이터 속성을 그대로 반영 이산형 : 셀 수 있는 값을 나타내는 데이터 연속형 : 측정 대상의 크기 변화가 연속적인 데이터

데이터 분류

■ 척도(scale)

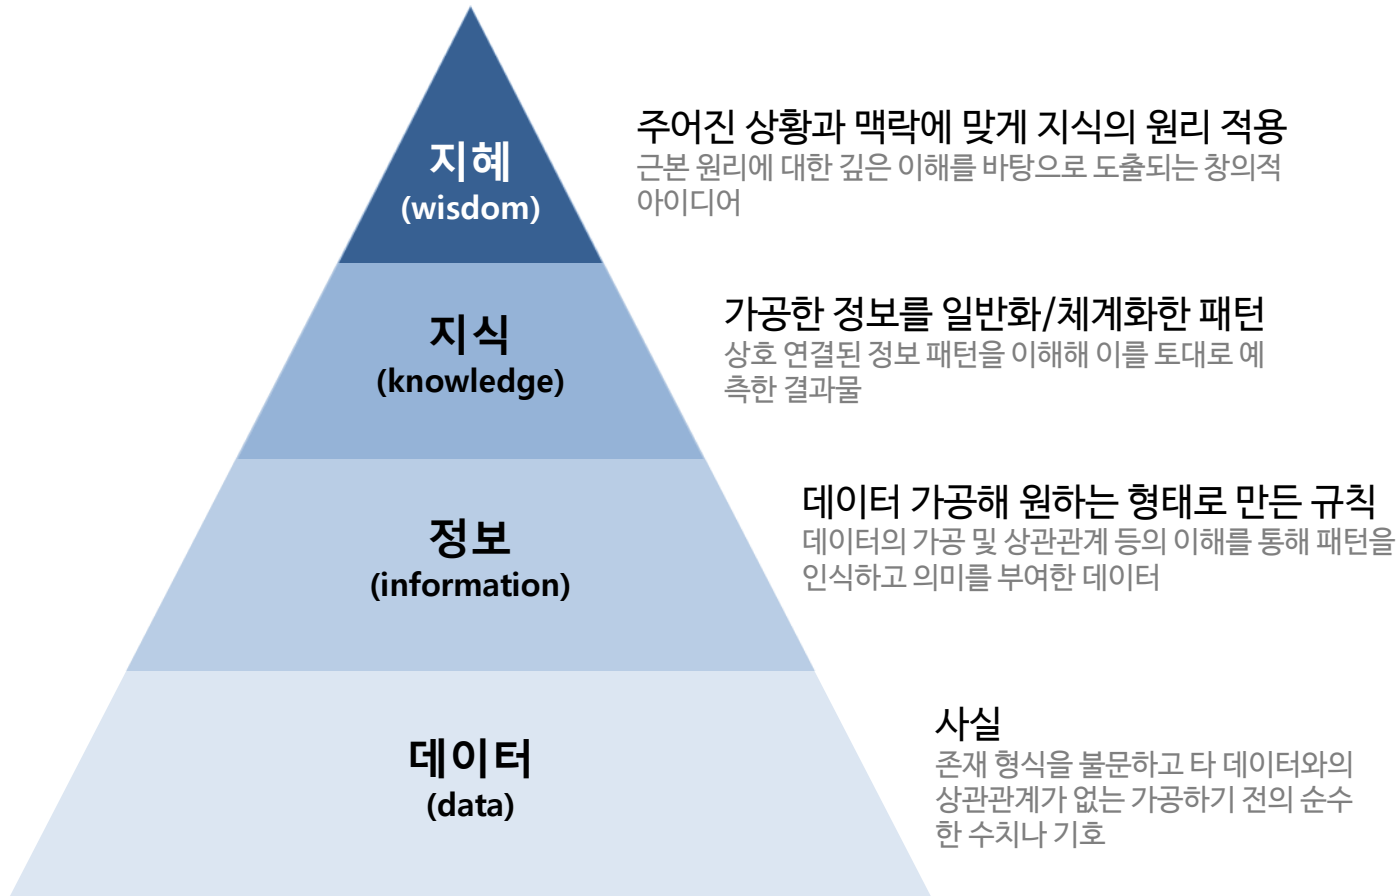
– 데이터를 측정하기 위해 임의로 부여한 숫자 간의 관계

구분	내용
명목척도 (nominal scale)	• 명목형 자료, 분류 • 예. 성별
서열(순서)척도 (ordinal scale)	• 순서형 자료, 서열 결정 • 예. 직급, 선호도
구간(등간)척도 (interval scale)	• 자료의 각 값이 동일한 간격으로 이뤄진 자료 • 상대적 순위 측정, 상대영점 • 예. 온도(섭씨, 화씨), 학점, 체온, 시력, 지수, 지능지수, 물가지수 등
비율척도 (ratio scale)	• 다른 것보다 몇배 더 큰가를 나타낼 수 있는 척도 • 절대 영(0)점이 존재(절대 영점은 값의 크기가 0), 사칙연산이 가능 • 상대적 크기, 간격, 몇 배 • 예. 키, 몸무게, 소득, 인구수, 길이, 나이 등



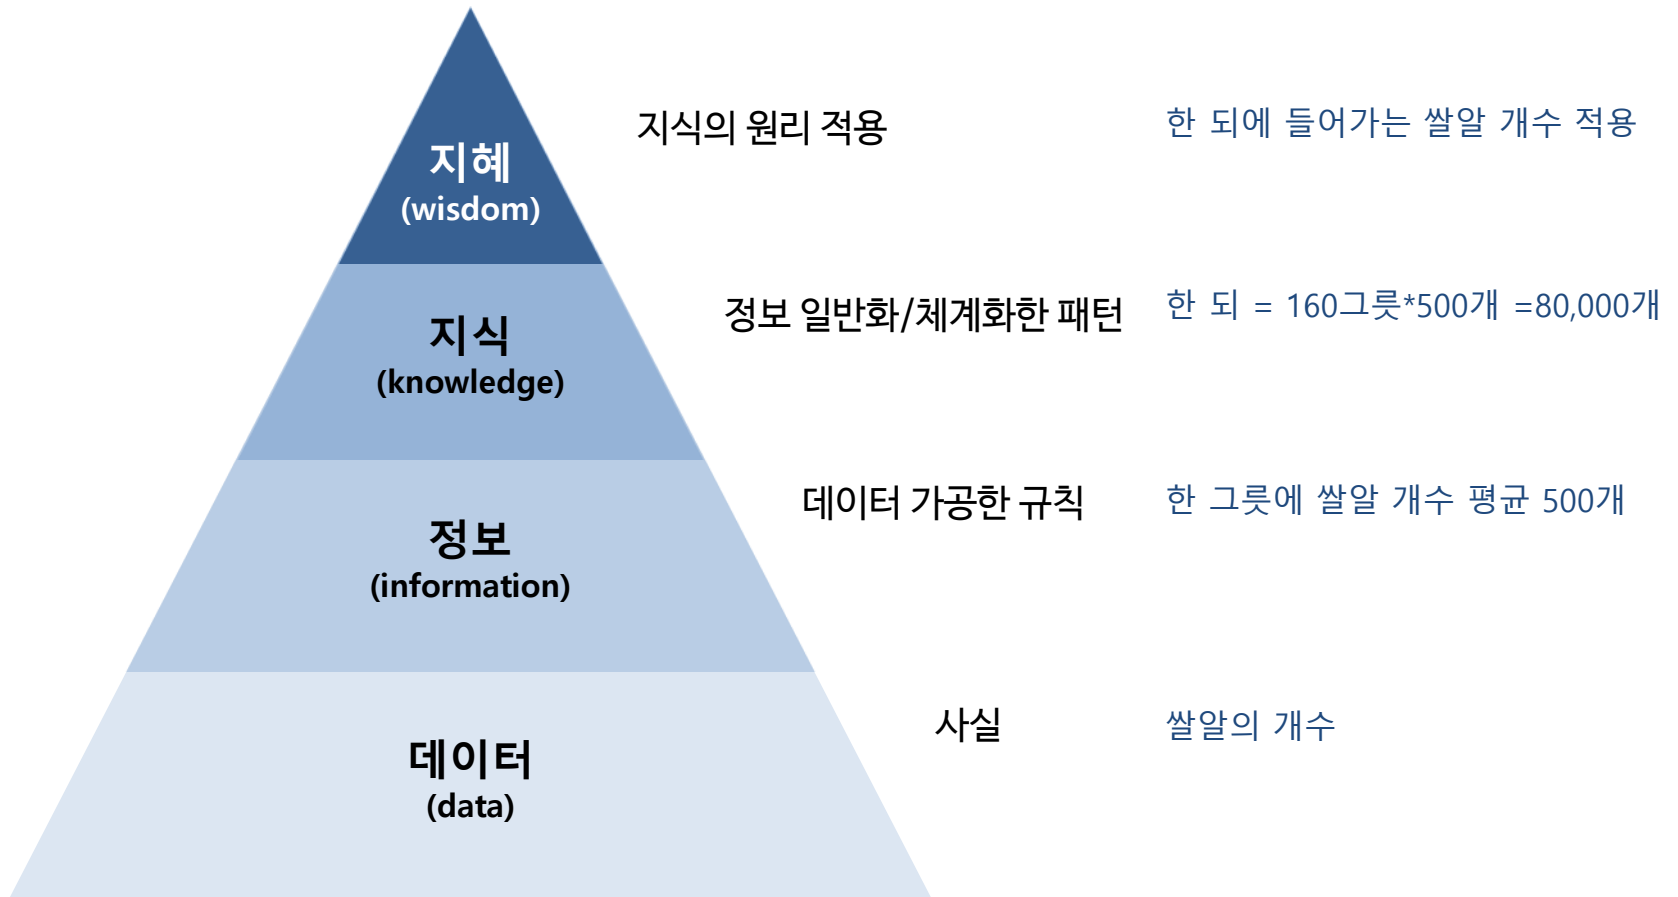
데이터-정보-지식-지혜

- 데이터는 모든 것의 근원



데이터-정보-지식-지혜

- 예. 쌀 한 가마니 속 쌀알의 개수는?



데이터 수집 절차

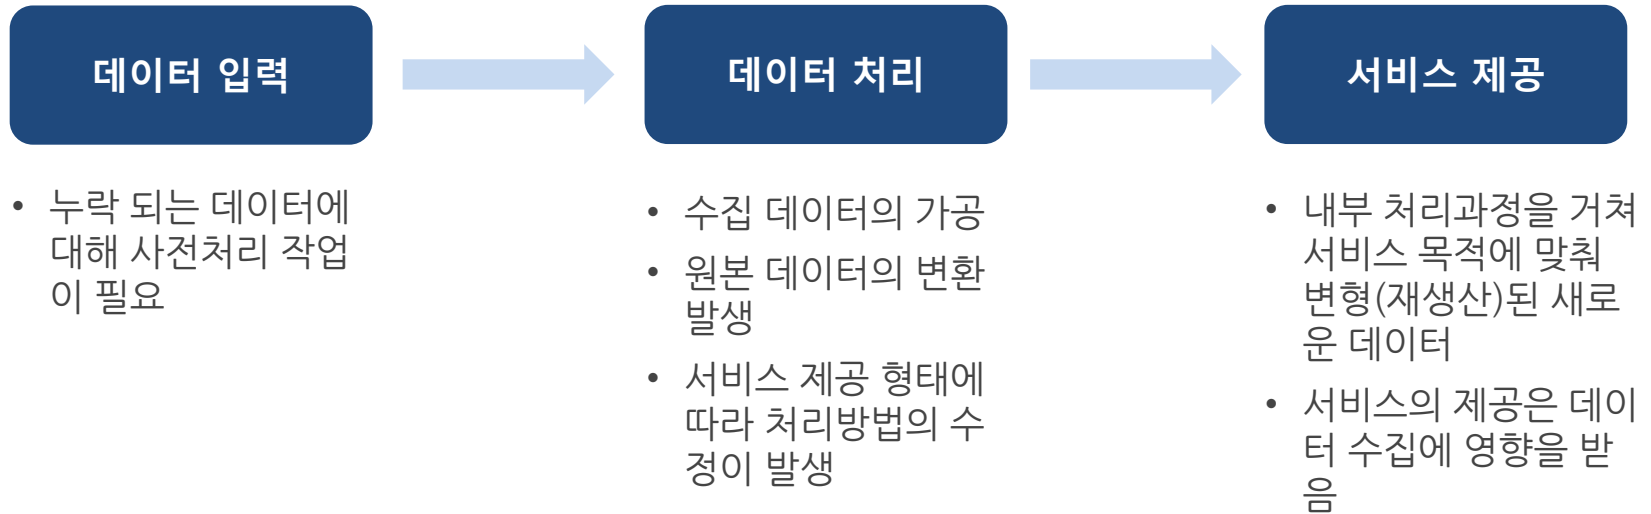
데이터 수집 절차

- 데이터를 수집하기 위해 수집절차를 설계하고 충분한 테스트를 걸쳐 수집을 진행해야 함
 - 데이터 수집은 서비스의 품질을 좌우
- 데이터 수집 프로젝트의 특징

프로세스	특징
데이터 입력	• 수집 프로세스 자체가 데이터 발생의 주체가 됨 • 수집 정책과 관련된 기술에 대한 데이터 오너십이 존재 • 데이터는 프로세스 하나에서 여러 건 발생 할 수 있음
데이터 처리	• 대부분 데이터의 전처리 과정이 필요 • 수집한 데이터에 대해 후처리(다른 데이터와 병합)가 이뤄짐
서비스 제공	• 처리된 데이터를 분리·병합해 새로운 인사이트를 제공하는 서비스가 주를 이룸 • 재생산의 과정을 거쳐 생성된 데이터가 출력 • 데이터 분석 관련 프로젝트가 주를 이룸

데이터 수집 절차

프로세스별 비교



데이터 수집 절차

■ 데이터 수집 절차 설계

데이터 선정

- 수집 가능성
- 보안 문제
- 데이터의 정확성
- 수집 비용



수집 세부계획 수립

- 수집 데이터 위치 파악 : 내부 / 외부
- 데이터 유형 파악 및 수집방법 적용 : 정형 / 반정형 / 비정형, RDB / 파일
- 수집계획서 작성 : 데이터 소스, 수집주기, 수집방법



테스트 수집 진행

- 수집 테스트 기술적 검토 : 데이터세트 누락, 소스 데이터와 비교, 데이터 정확성
- 수집 테스트 업무적 검토: 보안사항, 저작권, 대용량 트래픽

데이터 수집 절차

■ 데이터 수집 절차 설계

– 데이터 유형별 수집 방법

형태	데이터 유형	수집 방법
RDB	정형데이터, 비정형데이터	DB to DB, ETL, RDB 벤더제공 드라이버
파일	반정형데이터	크롤링, Open API, FTP, SFTP, HTTP

– 데이터 소스 구성 요소

항목	작성 내용	고려 사항
소스 위치	내부 시스템 : 특정 RDB의 IP, PORT 등 외부 시스템 : URI 등	여러 소스가 있을 경우 중요한 소스별로 모두 기술
데이터 유형	물리적으로 존재하는 데이터의 유형 기술: 파일 종류, RDB일 경우 DBMS 종류 등	데이터 유형이 혼합된 경우 의존관계 기술
인터페이스	수집하는 항목의 세부내용에 대한 인터페이스	
데이터 담당자	소스 데이터 담당자와 연락처 알지 못하는 경우 기관명 혹은 대표 URL	
협약 내용	데이터 원천 담당자와 협약한 내용 협약사항은 별도의 첨부 문서로 관리	법적 검토 필요

데이터 수집 절차

■ 데이터 수집 절차 설계

– 데이터 수집 주기 구성 요소

항목	작성 내용	고려사항
주기설정	배치처리와 실시간 처리로 구분 - 배치처리: . 주기성을 갖지 않는 불규칙 수집 . 일정시간을 정해 수집 - 실시간 처리 : 이벤트가 발생할 경우	수집실패 시 재수집 정책을 수립 필요
데이터량	1회 수집 시 발생하는 데이터의 양을 기술하고, 여기에 수집주기를 곱해 서비스 시작일과 서비스의 예상 종료일까지의 총 데이터량을 기술	수집실패 시 재수집 정책을 수립 필요
트래픽량	수집 시 발생하는 네트워크 트래픽량 계산	과도한 트래픽 발생 시 해결책 필요

데이터 수집 절차

- 데이터 수집 절차 설계
 - 데이터 수집 방법의 구성 요소

항목	작성 내용	고려사항
적용 기술	수집에 필요한 적용 기술을 기술 수집 프로세스별로 나누어 사용되는 기술의 이름, 버전을 기술	처리과정에 대해 과정 별로 나누어 기술
데이터 사전처리	사전 데이터 처리가 필요한 경우 사전 처리 작업 에 대해 기술	사전처리 규칙을 명시
데이터 사후처리	데이터 수집 후 사후처리가 방법	
대안 기술	소스 데이터 수집 시 대안기술이 필요할 경우 대 안 기술을 명시	대안기술이 존재하지 않을 경우 다른 데이 터 소스를 고려

데이터 수집 절차

■ 데이터 수집 절차 설계

– 데이터 수집 시 기술적 검토 사항

검토 사항	검토 방법
데이터 세트 누락	- 원본데이터 요청 후 확인 - 재수집을 통해 누락데이터 세트 확인
소스 데이터와 비교	- 파일인 경우 사이즈 비교 - 수집한 데이터와 개수 비교
데이터의 정확성	서비스 활용에 수집한 데이터의 사후처리가 필요한지 확인

– 데이터 수집 시 업무적 검토 사항


검토 사항	검토 방법
보안 사항	수집 데이터에 대한 개인정보 수집 등 보안 사항이 없는지
저작권	수집한 데이터가 저작권 등 법적 문제가 없는지
대용량 트래픽	수집 대상 시스템에 트래픽을 많이 발생시키는 요소가 없는지

데이터베이스

데이터베이스(database, DB)

■ 데이터 집합


- 여러 사람이 공유하여 사용할 목적으로 체계화해 통합, 관리하는 데이터의 집합
- 여러 응용 시스템들의 통합된 정보들을 저장하여 운영할 수 있는 공용 데이터들의 묶음
- 구조화된 정보 또는 데이터의 조직화된 모음으로서 일반적으로 컴퓨터 시스템에 전자적으로 저장
- 동시 접근 가능



이미지출처: 혼자공부하는 SQL, 한빛미디어

데이터베이스와 DBMS

- DBMS(DataBase Management System)
 - 데이터베이스를 관리하고 운영하는 소프트웨어 시스템



이미지출처: 혼자공부하는 SQL, 한빛미디어

데이터베이스와 DBMS


■ DBMS 종류

DBMS	제작사	작동운영체제	최신버전	기타
MySQL	Oracle	Unix, Linux, Windows, Mac	8.0	오픈소스(무료), 상용
MariaDB	MariaDB	Unix, Linux, Windows	10.6	오픈소스(무료)
PostgreSQL	PostgreSQL	Unix, Linux, Windows, Mac	12	오픈소스(무료)
Oracle	Oracle	Unix, Linux, Windows	18c	사용 시장 점유율1위
SQL Server	Microsoft	Windows	2019	주로 중/대형급 시장에서 사용
DB2	IBM	Unix, Linux, Windows	11	메인프레임 시장 점유율 1위
Access	Microsoft	Windows	2019	PC용
SQLite	SQLite	Android, iOS	3	모바일전용, 오픈소스(무료)

DBMS 발전 과정


■ 오프라인 관리

- 종이에 펜으로 기록




■ 컴퓨터에 파일로 저장

- 파일시스템
- 단점 : 데이터 양이 많아지면
데이터 중복성, 누락, 일관성(불일치) 결여



userID	name	birthYear	addr	mobile1	mobile2	height	mDate
BBK	바비킴	1973	서울 강남구	010	0000000	176	2013-05-05
EJW	이지원	1972	서울 강남구	011	8888888	174	2014-03-03
JKW	김지민	1965	서울 강남구	018	9999999	172	2010-10-10
JYP	정지민	1950	서울 강남구	011	4444444	166	2009-04-04
KBS	김지민	1979	서울 강남구	011	2222222	173	2012-04-04
KKH	김지민	1971	서울 강남구	019	3333333	177	2007-07-07
LJB	김지민	1963	서울 강남구	016	6666666	182	2009-09-09
LSG	이승기	1987	서울 강남구	011	1111111	182	2008-08-08
SSK	정지민	1979	서울 강남구	NULL	NULL	186	2013-12-12
YJS	정지민	1969	서울 강남구	NULL	NULL	170	2005-05-05




중복/불일치 발생

DBMS 발전 과정

■ 데이터베이스

- 1973년 에드거 프랭크 커드(E.F.Codd)
- 파일시스템의 단점 보완
- 대량의 데이터를 효율적으로 관리/운영
- DBMS
- SQL
 - DBMS에 데이터를 구축/관리/활용하기 위해 사용되는 언어
 - DBMS를 통해 중요한 정보들을 입력, 관리, 추출



DB/DBMS 특징

- **데이터 공유**

- 필요한 자료를 한번만 데이터베이스에 저장
- 모든 응용프로그램(사용자)이 공유
- 최신 데이터 유지, 일관성 보장

- **데이터 중복의 최소화**

- 동일한 데이터가 여러 개 중복되어 저장되는 것 방지

- **데이터 독립성**

- 데이터베이스 크기를 변경하거나 데이터 파일 저장소 변경 시 기존에 작성된 응용프로그램에는 영향을 미치지 않도록
- 데이터와 프로그램 분리

DB/DBMS 특징

▪ 데이터 무결성(integrity)

- 데이터베이스 안의 데이터는 오류가 없어야 함
- 데이터베이스에 저장된 데이터 값과 표현하는 현실 세계의 실제 값이 일치해야 함
- 데이터가 상호간에 모순이 없고 현실 세계에 모순되지 않도록 데이터 유지
 - 예1: 동일한 데이터가 두 곳에 저장되어 있는 경우, 어느 한 곳의 데이터만 갱신되고 다른 곳의 데이터는 갱신되지 않는 경우, 두 데이터 간의 불일치로 데이터의 무결성이 보장되지 않음
 - 예2: 현실 세계 모순 : 나이 300살
 - 예3: 데이터 상호간의 모순 : 은행 업무처리 시 고객과 소속 지점 간의 데이터 모순. 지점(A,B,C)만 존재하는데, 고객정보에 존재하지 않는 H지점을 기록할 경우

DB/DBMS 특징

▪ 데이터 무결성(integrity)

- 데이터베이스 시스템에서는 이러한 오류를 방지하기 위해 외래키(FK)를 사용하여 테이블간의 모순성 배제

도서번호	도서명	저자	출판사번호
			1001
			1001
			1003

출판사번호	출판사명	연락처
1001		
1002		
1003		

– 무결성 제약 조건

- 무결성을 보장하기 위해 정확하지 않은 데이터가 데이터베이스 내에 저장되는 것을 방지하기 위한 제약 조건


DB/DBMS 특징

■ 데이터 안정성 향상

- 대부분의 DBMS가 제공하는 백업·복원 기능 이용
- 데이터가 손상되는 문제가 발생할 경우 원상으로 복원, 복구하는 방법이 명확해짐

■ 보안


- 데이터베이스의 테이블에 따라 접근 권한을 다르게 하여 데이터베이스의 비밀 유지와 조작 방지



DB/DBMS 특징

■ 데이터 추상화

- 데이터베이스에서는 사용자에게 저장구조의 복잡성을 숨기고
- 테이블 개념만으로 DB를 생성/관리할 수 있도록 지원



■ 응용프로그램 제작 및 수정이 쉬워짐


- 통일된 방식으로 응용프로그램 작성 가능
- 유지보수 또한 쉬워짐

DB/DBMS 특징

▪ 다양한 뷰(View) 제공

– 다양한 형태(뷰)로 사용자에게 필요한 DBMS 데이터 세트 제공

- 수천 가지의 뷰 정의 가능
- 사용자 편의성 제고
- 보안 및 권한 관리



DBMS의 기능

- **데이터 정의(Definition)**
 - 데이터 구조를 정의
 - 데이터 구조에 대한 삭제/변경 기능 수행
- **데이터 조작(Manipulation)**
 - 데이터를 조작하는 소프트웨어(응용프로그램)가 요청하는 데이터의 검색, 삽입, 수정, 삭제 등의 작업 지원
- **데이터 제어(Control)**
 - 데이터베이스 사용자를 생성하고 모니터링하여 접근을 제어
 - 무결성, 보안 및 권한 검사, 백업과 회복, 동시성 제어 등의 기능 지원


DBMS의 분류

- 계층형(hierarchical)
- 망형(network)
- 관계형(relational)
- 객체지향형(object-oriented)
- 객체관계형(object-relational)
- NoSQL

DBMS의 분류

■ 계층형 DBMS

- 처음 등장한 DBMS 개념 - 1960년대에 시작
- 레코드를 계층구조로 표현 데이터 모델 사용
 - 각 계층은 트리Tree 형태, 1:N 관계
- 검색은 빠르지만 구조 변경이 어렵고 데이터 중복 문제 발생




이미지출처: 이것이 MySQL이다, 우재남, 한빛미디어

DBMS의 분류

■ 망형 DBMS

- 계층형 DBMS 문제점 개선을 위해 1970년대 시작
- 레코드 타입과 링크(Pointer들의 집합)로 구성
- 1:1, 1:N, N:M(다대다) 관계 지원 - 효과적이고 빠른 데이터 추출
- 복잡한 내부 포인터 사용




이미지출처. 이것이 MySQL이다, 우재남, 한빛미디어

DBMS의 분류

■ 관계형 DBMS

- 논리적 구조가 테이블(table) 형태
- E.F.Codd라는 학자가 수학 모델에 근거해 고안
- 데이터베이스는 테이블Table이라 불리는 최소 단위로 구성
 - 테이블은 하나 이상의 열과 행으로 구성




DBMS의 분류

- NoSQL

- Not Only SQL
 - SQL을 사용하지 않는다는 의미
 - SQL이 필요없다는 의미가 아니고, 개선/보완의 의미
- 관계형데이터베이스 보다 덜 제한적인 일관성 모델을 이용
- 키(Key)와 값(value) 형태로 저장
- 키를 이용해 데이터 관리 및 접근
- MongoDB

DBMS에서 사용되는 언어 : SQL

- SQL
 - Structured Query Language
 - 관계형 데이터베이스에서 사용되는 언어
 - 국제표준화기구에서 표준을 정해 발표 : 표준SQL



이미지출처. 혼자공부하는 SQL, 우재남, 한빛미디어

데이터 분석 이해

- 데이터 분석 개념
- 데이터 분석 과정
- 기본 용어 및 개념

데이터 분석 개념

■ 데이터 분석이란?

- 주어진 문제를 해결하기 위해 데이터를 다루는 과정
- 현상의 이해를 통해 미래를 예측하는 문제해결기법
- 인사이트를 도출하기 위해 알고리즘과 수학적 처리과정을 적용하여 해당 정보에 대한 결론을 도출하고 패턴을 찾는 과정

■ 데이터 분석의 목적

- 다양한 내/외부, 정형/비정형 데이터를 획득하여 새로운 통찰과 가치 창출
- 업무에 대한 문제해결 및 의사결정


데이터 분석 개념

■ 스몰데이터 분석과 빅데이터 분석

구분	스몰데이터 분석	빅데이터 분석
분석 목적	- 표본분석을 토대로 모집단의 특성을 추론하여 해석함 - 비교집단간 특성차이, 조치수단 간 효과차이 비교를 통해 관심대상 집단·수단을 선별하는데 중점	- 대규모 데이터에 숨어있는 패턴을 발견하고 규칙을 도출함 - 도출된 패턴 및 규칙을 이용해 개별대상별 (고객·제품 등) 액션방안 마련에 중점
데이터 수집	사용자를 대상으로 한 서베이나 포커스그룹 인터뷰 활용으로 상당한 조사기간이 수반됨	대규모 내부거래처리 데이터, 음성, 동영상, 외부공공 및 소셜데이터 활용으로 실시간에 가까운 분석
분석 기법	기술통계 및 차이분석, 회귀분석, 구조방정식 등 추론통계 중심	군집분석, 연관분석, 분류분석, 예측분석 등 정형 및 텍스트 마이닝 기법이 추가됨
분석 도구	전통적 SPSS, SAS 등 상용 통계분석 패키지 활용	R, 파이썬, 하둡 등의 오픈소스 및 클라우드 기반의 분석도구 활용
적용 분야	제조, 금융, 유통, 관광, 보건, 행정, 국방 등 공공 및 민간 전분야를 망라함	동일한 적용 분야를 가지며, 보다 다양한 데이터 소스 및 분석 기법 활용으로 분석 근거의 정확성과 예측력이 향상됨
분석 사용자	통계학 및 마이닝 전문가에게 의뢰를 통한 분석: Analysis	업무실무자 스스로 셀프 분석을 통한 의사결정에 활용: Analytics

데이터 분석 개념

■ 문제와 데이터 분석



* 출처 : 한국정보화진흥원, '알기쉬운빅데이터세상', 34쪽

데이터 분석 개념

▪ 다양한 분석 자원 추출

- 분석 대상/객체로부터 분석에 필요한 속성, 변수 추출
- 속성/변수 리스트
 - 예: 고객



- 이름, 전화, 주소, 성별, 연령, 결혼, 인종, 소득, 학력, 직업, 거주지 등



- 종교, 주택유형, 구독잡지, 보유자동차, 선호미디어, 취미활동 등



- 주이용 상품·서비스, 주이용 시간·장소, 총 이용빈도·거래금액, 최근 이용빈도·거래금액



- 이벤트 참여도, 반응도, 불만 의견, 요구사항 등

- 고객이 가진 다양한 속성들 중에서 문제해결에 필요한 속성을 선택하면 변수가 되며, 선택된 변수의 수치변화에 따라 문제의 원인-결과, 해결책을 찾을 수 있음


데이터 분석 과정

▪ 데이터 분석 결과물 형태

구분	시각화(Visualization)	모델(model)
방법론	탐색적 자료 분석(EDA)	회귀분석, 머신러닝 등
목적	현황 파악, 새로운 사실 도출 등	예측, 분류 등
형태	표, 그래프, 워드 클라우드, 텍스트 등	수식, 모델 등
예시	- 월별 매출 현황분석, 구매고객 특징분석 - 상관분석, 가설검정, 뉴스기사분석 등	- 일사량에 따른 태양광 발전 출력 예측 - 이미지 판별 모델, 금융사기 판별 모델 - 자연어 처리 모델 등
최종산출물	보고서, 대시보드	시스템


데이터 분석 과정

데이터 분석 과정

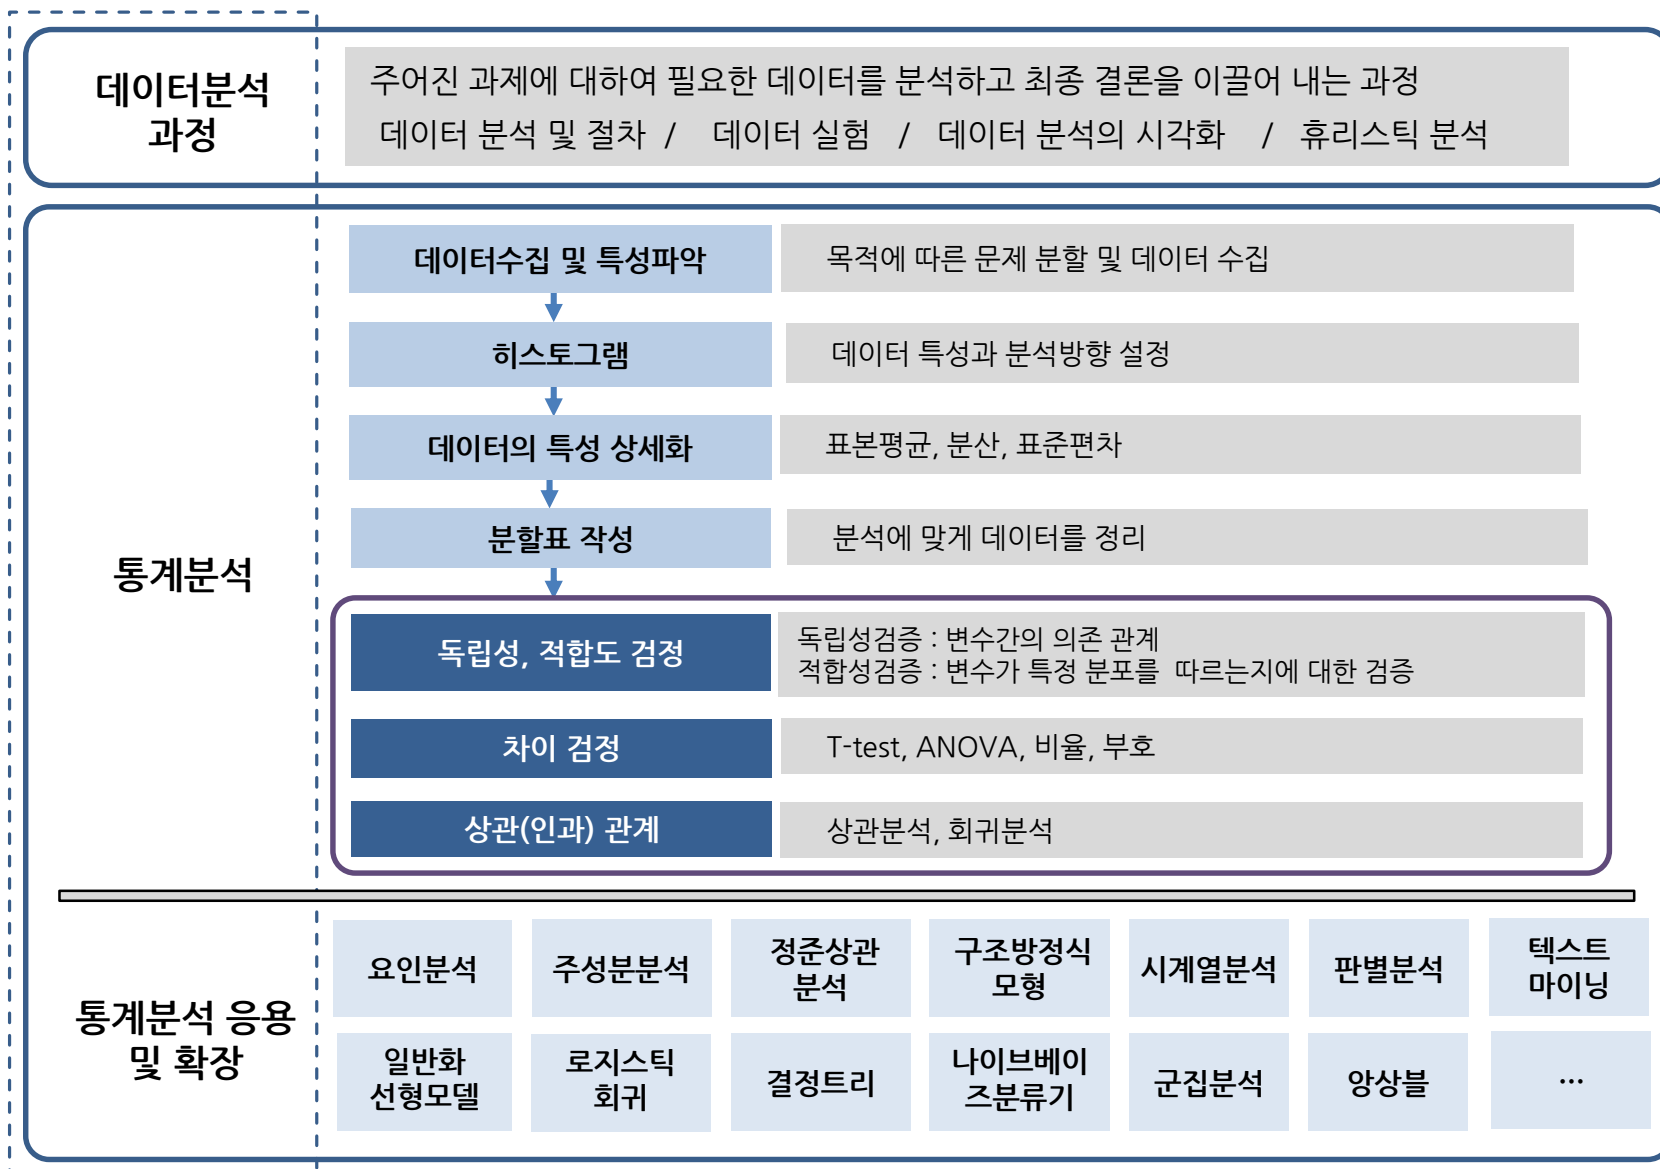


데이터 분석 과정

데이터 분석 가이드 맵




데이터 분석 과정




데이터 분석 과정

통계분석 기법들



통계학과 인공지능



출처: <https://www.altexsoft.com/whitepapers/machine-learning-bridging-between-business-and-data-science/>

<https://blogs.sas.com/content/subconsciousmusings/2014/08/22/looking-backwards-looking-forwards-sas-data-mining-and-machine-learning/>

통계학과 인공지능

STATISTICS



Limited data samples

Focusing modeling
& Tight assumptions

소수에서 다수를 추정

MACHINE LEARNING



Lots of data samples

Focusing optimization
& No rigid assumptions

과거에서 미래를 예측



-----> **MODELING** <-----

출처:

<https://davicinilabs.ai/blog/?q=YToyOntzOjEyOiRZXl3b3JkX3R5cGUiO3M6MzoiYWxsljtzOjQ6InBhZ2UiO2k6Mzt9&bmode=view&idx=10608836&t=board>

기본 용어 및 개념

- **통계(statistic, 統計)**

- 사람, 사물·사건, 사회적 현상 혹은 자연 현상 등을 조사해 수집된 각종 데이터의 요약
- 집단현상에 대한 구체적인 양적 기술을 반영하는 숫자 (by 두산백과)

- **통계학(statistics)**

- 산술적 방법을 기초로 하여 주로 다량의 데이터를 관찰하고 정리 및 분석하는 방법을 연구하는 수학의 한 분야 (by Wikipedia)

- **인공지능(Artificial Intelligence)**

- 인간의 학습 능력, 추론 능력, 지각 능력, 자연언어의 이해 능력 등을 컴퓨터 프로그램으로 실현한 기술


- **머신러닝(Machine Learning)**

- AI의 하위집합, 기계가 경험을 바탕으로 스스로 개선해가는 기법

기본 용어 및 개념

모집단과 표본

- 모집단(population)
 - 조사 대상이 되는 관측 가능한 개체로 된 집단 전체
- 표본(sample)
 - 모집단에서 선택된 모집단 구성단위의 일부



기본 용어 및 개념

- **전수조사와 표본조사**

- 전수조사
 - 모집단 전체를 조사
- 표본조사
 - 모집단의 일부를 조사


- **모수와 통계량**

- 모수(parameter)
 - 모집단의 특성을 나타내는 수치
- (표본)통계량(sample statistic)
 - 표본의 특성을 나타내는 수치


기본 용어 및 개념

기술통계(descriptive statistics)	추측통계(inferential statistics)
- 수집한 데이터를 요약, 묘사, 설명하는 기법 예. 인구조사, 토지조사 등을 통한 현상 파악 - 시각화도구 : 도수분포표, 히스토그램, 상자그림표, 산점도, 버블차트, 히트맵, 평행좌표플롯 등 - 기술통계량 : 평균, 중위수(중앙값), 사분위수, 분산, 표준편차, 변동계수, 왜도, 첨도 등	- 수집한 데이터를 기반으로 모집단의 특성을 추론 예측하는 기법 - 전체를 파악할 수 없을 정도의 큰 대상이나 아직 발생하지 않은 미래의 일에 대해 추측하는 기술 예. 대선의 당선 확률 예측, 주가예상, 금융/보험 상품의 가격 결정 등 - 확률이론 기반 - 가설검정을 기반으로 한 통계적 분석 기법들 : 상관분석, 연관분석, 독립성검정, 차이검정, 회귀분석, 구조방정식 등

기본 용어 및 개념



- 데이터 탐색과 시각화
- 차원 축소: 요인분석, 주성분분석
- 연관성 : 연관규칙(장바구니 분석), 상관분석
- 군집화 : 계층적 군집분석, 분할적 군집분석(K-means)



- 회귀분석
- 일반화선형모델
- 분류 : 판별분석, 로지스틱 회귀분석, 나이브 베이즈 분류기, 분류 회귀나무, 신경망
- 연속성 : 시계열분석

기본 용어 및 개념

▪ 데이터 마이닝 적용 분야

적용분야	내용
분류(Classification)	일정한 집단에서 특정한 정의를 이용하여 분류 및 구분을 추론 예. 경쟁자에게로 이탈한 고객을 분류
군집화(Clustering)	구체적인 특성을 공유하는 군집을 찾음 군집화는 미리 정의된 특성의 정보가 없다는 점에서 분류와 다름 예. 비슷한 행동 집단을 구분
연관성(Association)	동시에 발생한 사건 간의 관계를 정의 예. 장바구니 안에 동시에 들어가는 상품들의 관계 규명
예측(Forecasting)	방대한 양의 데이터 집합의 패턴을 기반으로 미래를 예측 예. 수요 예측
연속성(Sequencing)	특정 기간에 걸쳐 발생하는 관계를 규명 시간에 따라 순차적으로 나타나는 사건의 종속성