



## 데이터 핸들링 : pandas

- Python Data Analysis Library
- pandas 이름 => panel data + python data analysis
- 데이터 가공/처리를 위해 최적화된 파이썬 라이브러리
  - 데이터분석 업무의 80~90%는 데이터 수집과 정리하는 일
- Wes McKinney 개발 : 월스트리트 금융회사 분석 전문가
- numpy 기반으로 작성되었지만
- numpy 보다 훨씬 유연하고 편리하게 데이터 핸들링 가능
- 공식사이트 : <https://pandas.pydata.org/>

## 핵심객체 : 데이터프레임(DataFrame)

- R의 데이터프레임을 모방
- 데이터를 수정하고 목적에 맞게 변경시키기 위해 사용
- 데이터 프레임은 엑셀과 유사
- numpy를 사용하고 있어 계산이 빠름
- 라이브러리 구성
  - 여러 종류의 클래스와 다양한 함수로 구성
  - 시리즈와 데이터 프레임의 자료 구조 제공
  - 시리즈(컬럼이 하나), 데이터프레임(컬럼이 여러 개)

## 판다스의 목적

- 서로 다른 유형의 데이터를 공통된 포맷으로 정리하는 것
- 행과 열로 이루어진 2차원 데이터프레임을 처리 할 수 있는 함수제공 목적
- 실무에서 사용하는 데이터 유형 : 데이터 프레임

## pandas 모듈 импорт

```
In [1]: # pandas 모듈 import
# 대부분의 코드에서 pandas를 pd 라는 별칭으로 사용

import pandas as pd
```

```
In [2]: pd.__version__
```

```
Out[2]: '3.0.5'
```


## pandas의 데이터 구조

1. Series 데이터
2. 데이터 프레임

# Pandas Data Structures

## Series

A one-dimensional labeled array capable of holding any data type




|   |    |
|---|----|
| A | 3  |
| B | -5 |
| C | 7  |
| D | 4  |

```
>>> s = pd.Series([3, -5, 7, 4], index=['a', 'b', 'c', 'd'])
```

## DataFrame

Columns



|   | Country | Capital   | Population |
|---|---------|-----------|------------|
| 1 | Belgium | Brussels  | 11190846   |
| 2 | India   | New Delhi | 1303171035 |
| 3 | Brazil  | Brasília  | 207847528  |

A two-dimensional labeled data structure with columns of potentially different types

```
>>> data = {'Country': ['Belgium', 'India', 'Brazil'],
            'Capital': ['Brussels', 'New Delhi', 'Brasília'],
            'Population': [11190846, 1303171035, 207847528]}

>>> df = pd.DataFrame(data,
                       columns=['Country', 'Capital', 'Population'])
```

- 출처 : <https://www.kdnuggets.com/2017/01/pandas-cheat-sheet.html>