

pandas 데이터 파악과 조작

분석할 데이터를 수집(확보)하면 데이터의 특징을 파악하고 다루기 쉽게 변형하는 작업을 수행해야 한다

```
In [1]: import numpy as np
import pandas as pd
print(f'Numpy:{np.__version__}, Pandas:{pd.__version__}')
```

Numpy:2.5.2, Pandas:3.0.5

```
In [2]: from IPython.core.interactiveshell import InteractiveShell
# InteractiveShell.ast_node_interactivity = 'all'
```

#1. 데이터 파악

데이터가 주어졌을때 가장 먼저 하는일은 데이터의 전반적인 구조를 파악하면서 데이터의 특징에 대한 감을 잡는다

- 데이터는 어떤 모양인가?
- 데이터의 크기?
- 어떤 변수들로 구성되었는가?
- 결측치가 있는가?

데이터를 파악하기 위해 사용하는 pandas 명령어

데이터 내용 미리보기

- **head()** : 데이터의 앞부분 출력
- **tail()** : 데이터의 뒷부분 출력

데이터 요약 정보 확인하기

- **shape** : 데이터의 행,열 개수 출력
- **info()** : 데이터 기본 정보 확인
- **describe()** : 요약 통계량 출력

예제 데이터. 타이타닉 데이터

- data 출처: <https://www.kaggle.com/hesh97/titanicdataset-traincsv/data>
- 'data' 폴더 생성 후 'train.csv'를 'titanic.csv'로 변경하여 저장하기

```
In [3]: df_tit = pd.read_csv('data/train.csv')
```

데이터 앞/뒤 부분 확인하기 : head(), tail()

- **DataFrame.head(n=5)**
- **DataFrame.tail(n=5)**

```
In [4]: df_tit.head()
```

Out[4]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...)	female	38.0	1	0	PC 17599	71.2833	C85	
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	

In [5]:

```
df_tit.tail()
```

Out[5]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.00	NaN	
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.00	B42	
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.45	NaN	
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.00	C148	
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.75	NaN	

In [6]:

```
df_tit.head(n=3)
```

Out[6]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...)	female	38.0	1	0	PC 17599	71.2833	C85	
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	

In [7]: df_tit.tail(3)

Out[7]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.45	NaN	
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.00	C148	
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.75	NaN	

데이터 크기 확인 : shape

- 데이터프레임의 행,열 수를 튜플로 반환

In [9]: df_tit.shape

Out[9]: (891, 12)

In [11]: df_tit.size

Out[11]: 10692

데이터 기본 정보 확인 : info()

- 클래스 유형
- index의 dtype과 개수, columns의 수
- column별 non-null values의 개수, dtype
- memory 사용크기

In [12]: df_tit.info()

```
<class 'pandas.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  -
0   PassengerId     891 non-null    int64
1   Survived        891 non-null    int64
2   Pclass          891 non-null    int64
3   Name            891 non-null    str
4   Sex             891 non-null    str
5   Age             714 non-null    float64
6   SibSp           891 non-null    int64
7   Parch           891 non-null    int64
8   Ticket          891 non-null    str
9   Fare            891 non-null    float64
10  Cabin           204 non-null    str
11  Embarked        889 non-null    str
dtypes: float64(2), int64(5), str(5)
memory usage: 83.7 KB
```

요약 통계량 구하기 : describe()

- 형식:

```
describe(percentiles=None, include=None, exclude=None, datetime_is_numeric=False)
```

- NaN을 제외한 데이터에 대한 데이터의 중심경향(central tendency),산포(dispersion),모양(shape)을 대표하는 기술통계량 계산 출력

- 중심 : 평균(mean), 중위수(median), 백분위수(percentile), 최소값(min), 최대값(max)
- 산포 : 표준편차(std)
- 빈도 : 개수(count), 최빈값(top), freq, unique

```
In [13]: df_tit.describe()
```

```
Out[13]:
```

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200

describe(include='all') : 문자 변수 요약 통계량 함께 출력

- unique : 중복을 제거한 범주의 개수
- top : 최빈값
- freq : 최빈값 빈도

```
In [14]: df_tit.describe(include='all')
```

Out[14]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Tic
count	891.000000	891.000000	891.000000	891	891	714.000000	891.000000	891.000000	
unique	NaN	NaN	NaN	891	2	NaN	NaN	NaN	
top	NaN	NaN	NaN	Braund, Mr. Owen Harris	male	NaN	NaN	NaN	347
freq	NaN	NaN	NaN	1	577	NaN	NaN	NaN	
mean	446.000000	0.383838	2.308642	NaN	NaN	29.699118	0.523008	0.381594	N
std	257.353842	0.486592	0.836071	NaN	NaN	14.526497	1.102743	0.806057	N
min	1.000000	0.000000	1.000000	NaN	NaN	0.420000	0.000000	0.000000	N
25%	223.500000	0.000000	2.000000	NaN	NaN	20.125000	0.000000	0.000000	N
50%	446.000000	0.000000	3.000000	NaN	NaN	28.000000	0.000000	0.000000	N
75%	668.500000	1.000000	3.000000	NaN	NaN	38.000000	1.000000	0.000000	N
max	891.000000	1.000000	3.000000	NaN	NaN	80.000000	8.000000	6.000000	N

In [15]:

```
df_tit.describe(include='str')
```

Out[15]:

	Name	Sex	Ticket	Cabin	Embarked
count	891	891	891	204	889
unique	891	2	681	147	3
top	Braund, Mr. Owen Harris	male	347082	G6	S
freq	1	577	7	4	644

In [16]:

```
df_tit.describe(include=['float64','str'])
```

Out[16]:

	Name	Sex	Age	Ticket	Fare	Cabin	Embarked
count	891	891	714.000000	891	891.000000	204	889
unique	891	2	NaN	681	NaN	147	3
top	Braund, Mr. Owen Harris	male	NaN	347082	NaN	G6	S
freq	1	577	NaN	7	NaN	4	644
mean	NaN	NaN	29.699118	NaN	32.204208	NaN	NaN
std	NaN	NaN	14.526497	NaN	49.693429	NaN	NaN
min	NaN	NaN	0.420000	NaN	0.000000	NaN	NaN
25%	NaN	NaN	20.125000	NaN	7.910400	NaN	NaN
50%	NaN	NaN	28.000000	NaN	14.454200	NaN	NaN
75%	NaN	NaN	38.000000	NaN	31.000000	NaN	NaN
max	NaN	NaN	80.000000	NaN	512.329200	NaN	NaN

In [17]:


```
df_tit.describe(exclude='int64')
```

Out[17]:

	Name	Sex	Age	Ticket	Fare	Cabin	Embarked
count	891	891	714.000000	891	891.000000	204	889
unique	891	2	NaN	681	NaN	147	3
top	Braund, Mr. Owen Harris	male	NaN	347082	NaN	G6	S
freq	1	577	NaN	7	NaN	4	644
mean	NaN	NaN	29.699118	NaN	32.204208	NaN	NaN
std	NaN	NaN	14.526497	NaN	49.693429	NaN	NaN
min	NaN	NaN	0.420000	NaN	0.000000	NaN	NaN
25%	NaN	NaN	20.125000	NaN	7.910400	NaN	NaN
50%	NaN	NaN	28.000000	NaN	14.454200	NaN	NaN
75%	NaN	NaN	38.000000	NaN	31.000000	NaN	NaN
max	NaN	NaN	80.000000	NaN	512.329200	NaN	NaN

탐색적 데이터 분석(EDA)

- Exploratory Data Analysis
- 데이터 특성을 파악하고 상세화
- 데이터 유형(속성)에 따라 데이터의 특성을 파악한 후 분석 방향 결정



데이터 유형(범주형/수치형)에 따른 EDA 기법

	범주형 자료	수치형 자료
시각화도구	• 도수분포표, 분할표 • 파이차트, 막대그래프, 모자익플롯 등	• 히스토그램, 선그래프, 박스플롯, 산점도, 버블차트, 히트맵 등
기술통계량	• 빈도, 비율 등	• 평균, 중위수(중앙값), 사분위수, 분산, 표준편차, 왜도, 첨도 등

기술통계량(Descriptive Statistic)

: 데이터의 특징을 수치로 요약, 기술하는 통계량

- 위치통계량(measure of location)


- 데이터의 중심경향(central tendency)을 나타내는 척도
- 대표값이라고도 부름
- 수치형자료 : 평균(산술/조화/기하), 중위수, 절사평균, 사분위수 등
- 범주형자료 : 최빈수

- 변이통계량(measure of location)

- 데이터의 퍼짐, 흩어진 정도(산포:dispersion)를 나타내는 척도
- 산포도라고도 부름
- 수치형자료 : 분산, 표준편차, 사분위간범위, 범위 등
- 범주형자료 : 범주별 빈도

- 모양통계량(measure of shape)

- 왜도(skewness) : 데이터가 중심 위치로부터 어느 한쪽으로 치우친(비대칭) 정도를 나타내는 척도
- 첨도(kurtosis) : 분포의 뾰족함 정도



기술통계량 관련 API 함수들

<https://numpy.org/doc/stable/reference/routines.statistics.html>

<https://pandas.pydata.org/docs/reference/series.html>

<https://pandas.pydata.org/docs/reference/frame.html>

<https://docs.scipy.org/doc/scipy/reference/stats.html>

구분	통계량	관련 API
위치통계량 (measure of location)	산술평균(arithmetic mean) $\frac{\sum_{i=1}^n X_i}{n}$	- pandas.Series.mean() - pandas.DataFrame.mean() - numpy.mean()
	조화평균(harmonic mean) $\frac{1}{(\frac{1}{X_1} + \frac{1}{X_2} + \dots + \frac{1}{X_n})/n}$: 비율 및 변화율에 대한 평균	scipy.stats.hmean()
	기하평균(geometric mean) $\sqrt[n]{X_1 \times X_2 \times \dots \times X_n}$: 성장률의 평균	scipy.stats.gmean()
	가중평균(weighted mean)	- np.average() - scipy.stats.pmean()
	절사평균(trimmed mean) : 자료의 상,하위를 값을 제외한 나머지 데이터의 산술평균	scipy.stats.trim_mean()
	중앙값(median) : 자료를 정렬하여 가장 가운데 위치하는 수(50%)	- pandas.DataFrame.median() - pandas.Series.median() - numpy.median()
	최소값(minimum value)	- pandas.DataFrame.min() - pandas.Series.min() - numpy.min()
	최대값(maximum value)	- pandas.DataFrame.max() - pandas.Series.max() - numpy.max()
	- 제1사분위수(제25백분위수, 하사분위수 lower quartile) - 제3사분위수(제75백분위수, 상사분위수 upper quartile)	- numpy.percentile() - numpy.quantile()
	- 최빈값(mode) - 빈도	- pandas.Series.value_counts() - scipy.stats.mode() - scipy.stats.mode().mode - scipy.stats.mode().count


구분	통계량	관련 API
변이통계량 (measure of dispersion)	범위(range) : 최대값 - 최소값	max() - min()
	중간범위 : 최대값과 최소값의 평균	(max()+min())/2
	사분위간범위(IQR:Inter Quartile Range) : 상사분위수-하사분위수	- np.quantile(, 0.75) - np.quantile(, 0.25) - scipy.stats.iqr()
	사분위수편차(quartile deviation) : 사분위간 범위를 2로 나눈값	
	편차(deviation) : 자료값과 평균과의 차이	
	분산(variance) : 평균과의 편차의 제곱합들의 평균	- pandas.DataFrame.var() - pandas.Series.var() - numpy.var()
	표준편차(standard deviation) : 분산의 제곱근	- pandas.DataFrame.std() - pandas.Series.std() - numpy.std()
	변동계수(Coefficient of Variable : CV) - 표준편차를 평균으로 나누어 100을 곱한값 - 상대표준편차	scipy.stats.variation()

구분	통계량	관련 API
모양통계량 (measure of shape)	왜도(skewness) : 자료의 비대칭도 - 정규분포의 왜도 = 0 - positive skewness(오른쪽꼬리긴분포) : 왜도 > 0 - negative skewness(왼쪽꼬리긴분포) : 왜도 < 0 왜도의 절대값이 1.5 이상이면 비대칭정도 심하다고 판단	- pandas.Series.skew() - pandas.DataFrame.skew() - scipy.stats.skew()
	첨도(kurtosis) : 평균중심으로 물려있는 정도 - 정규분포의 첨도 = 0 (Fisher's definition) - 첨도 > 0 : 뾰족, 첨도 < 0 : 완만 균일분포에 가까울수록 첨도는 음수값	- pandas.Series.kurtosis() - pandas.DataFrame.kurtosis() - scipy.stats.kurtosis()

시각화 도구를 통한 데이터 파악

: 데이터의 변수 수, 종류(유형), 분석 목적에 따라 시각화 도구가 달라짐

데이터종류	변수의 수	시각화 도구
<u>수치형데이터</u>	<u>일변량</u>	도수분포표
		상자그림
		히스토그램
	<u>이변량</u>	<u>산점도</u>
		선그래프
	<u>다변량</u>	<u>산점도행렬</u>
방사선차트		
평행좌표		
<u>범주형데이터</u>	<u>일변량</u>	<u>빈도표</u>
		파이차트
		막대차트
	<u>이변량</u>	<u>교차표</u>
		<u>스택트컬럼차트</u>
	<u>다변량</u>	<u>모자익플롯</u>



출처: <https://blog.qlik.com/third-pillar-of-mapping-data-to-visualizations-usage>

pandas의 plot 함수

구분	데이터유형	플롯	관련 API
Single variable	수치형	• 박스플롯(box-plot) • 히스토그램(histogram)	• pandas.DataFrame.box() • pandas.boxplot() • pandas.DataFrame.hist() • pandas.hist()
	범주형	• 막대그래프(bar chart) • 파이차트(pie chart)	• pandas.DataFrame.bar() • pandas.DataFrame.barh() • pandas.DataFrame.pie()
Two variables	수치형, 수치형	• 산점도(scatterplot) • 선그래프(lineplot) • 영역그래프(area plot)	• pandas.DataFrame.scatter() • pandas.DataFrame.line() • pandas.DataFrame.area()