

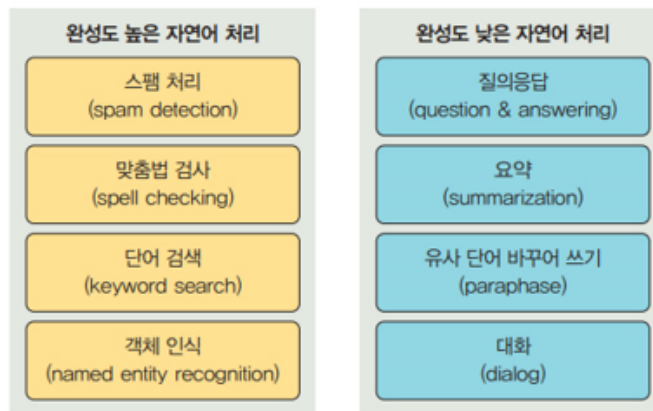
텍스트 분석 이해

1. NLP(Natural Language Processing)와 텍스트 분석(text analytics)

1) 자연어처리(Natural Language Processing, NLP)

- 머신이 인간의 언어를 이해하고 해석하고 조작(표현)할 수 있도록 연구하고 구현하는 인공지능의 분야
- 1950년대 부터 연구해 옴
- 핵심기술 : 형태소 분석, 구문 분석, 의미분석, 단어 및 문장 생성
- 텍스트분석을 향상하게 하는 기반 기술
- 응용
 - 정보 검색
 - 문서 자동분류
 - 텍스트 요약 (ex: Summly)
 - 대화 시스템 (ex: Apple Siri)
 - 기계 번역 (ex: Google Translate)
 - 챗봇


자연어 처리 완성도



2) 텍스트 분석

- 자연어처리 과정을 통해 추출된 단어나 문장 속에서 의미있는 정보(insight)를 추출하는 것에 중점을 둔 영역
- 텍스트 마이닝(text mining)

[그림] 텍스트 마이닝(Text-mining) 과 자연어 처리의 범위 (출처: linguamatics)



<https://blog-ko.superb-ai.com/the-hidden-treasures-of-nlp-and-text-mining/>

*자연어처리가 텍스트를 분석할 수 있도록 처리기술을 제공하고, 텍스트 분석은 그 기술을 활용해 실제 데이터에서 정보를 찾아냄

구분	자연어처리(NLP)	텍스트 분석(Text Analytics)
주요 목적	인간의 언어를 컴퓨터가 처리하도록 구현	텍스트에서 정보·패턴·인사이트 발견
중심 관점	언어처리 기술과 모델 개발	데이터 탐색과 분석 결과 해석
주요 질문	컴퓨터가 문장을 어떻게 이해하고 생성할까?	텍스트 데이터에서 무엇을 발견할 수 있을까?
입력 데이터	텍스트, 음성, 대화	주로 문서나 텍스트 데이터
주요 작업	형태소 분석, 번역, 요약, 질의응답, 생성	빈도 분석, 키워드 분석, 감성분석, 토픽 분석
주요 기술	형태소 분석기, Transformer, BERT, LLM	빈도, TF-IDF, 통계분석, 시각화, 군집화
결과물	번역문, 요약문, 분류 모델, 대화 응답	분석표, 그래프, 핵심 키워드, 경향과 인사이트
주요 사용자	NLP-AI 엔지니어, 연구자	데이터 분석가, 마케터, 기획자, 연구자

2. 텍스트 분석의 변천

시기	주요 기술	텍스트 표현	특징과 한계
1950~1960년대	규칙 기반 NLP, 기계번역	단어·문법 규칙	전문가가 사전과 문법 규칙을 직접 작성
1970~1980년대	형태소 분석, 구문 분석, 전문가 시스템	사전·규칙·구문 트리	설명 가능하지만 확장과 유지보수가 어려움
1990년대	통계적 NLP, 정보검색	BoW, TF-IDF, N-gram	대규모 말뭉치에서 확률과 빈도를 학습
2000년대	머신러닝 기반 분류	희소 벡터	Naive Bayes, SVM, 토픽 모델 등이 확산
2010~2016년	신경망 NLP	Word2Vec, GloVe, 임베딩	단어의 의미 관계를 밀집 벡터로 표현
2014~2017년	RNN, LSTM, GRU, Attention	문맥 기반 순차 벡터	단어 순서와 문맥을 처리하지만 병렬화에 한계
2017~2019년	Transformer, 사전학습 모델	문맥적 임베딩	Self-Attention으로 긴 문맥과 병렬처리 개선
2020년 이후	대규모 언어모델	토큰·문맥 임베딩	하나의 모델이 다양한 언어 작업을 수행
최근	RAG, 멀티모달, AI Agent	텍스트+이미지+음성+검색정보	생성·검색·추론·도구 사용으로 범위 확장



- 단어의 출현 횟수를 계산하던 기술에서, 문맥과 의미를 학습하고 지식을 검색하며 작업까지 수행하는 기술로 발전
 - 과거 : 텍스트를 구성하는 언어적인 룰이나 업무의 룰에 따라 텍스트를 분석하는 rule-based system
 - 현재 : 머신러닝의 텍스트 데이터를 기반으로 모델을 학습하고 예측

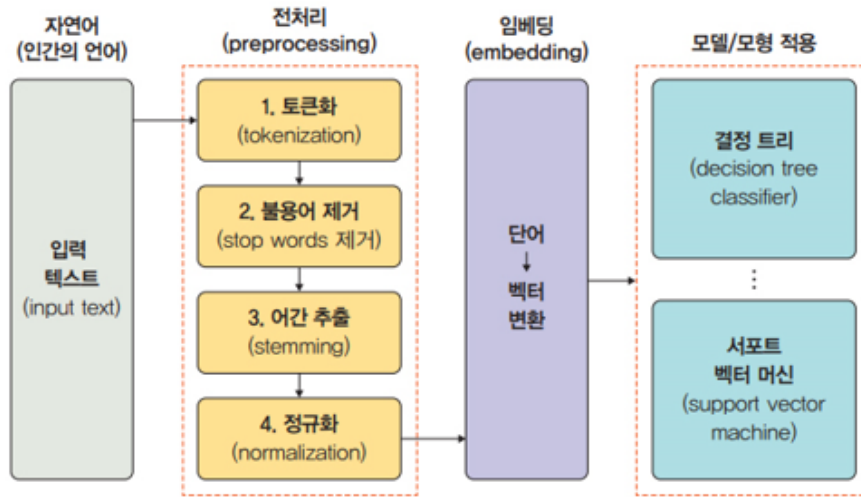
변화 관점	과거	현재
지식 생성	사람이 규칙 작성	모델이 데이터에서 학습
텍스트 표현	단어 빈도	문맥 임베딩
분석 단위	단어·형태소	서브워드·문장·문서
문맥 처리	거의 불가능	긴 문맥 관계 처리
모델 구성	작업별 개별 모델	범용 사전학습 모델
학습 방식	지도학습 중심	자기지도 사전학습
사용 방식	코딩과 모델 학습	프롬프트·검색·도구 연결
주요 결과	분류·통계	생성·요약·추론·실행

3. 텍스트 분석 기술 영역

: 머신러닝, 언어 이해, 통계 등을 활용해 모델을 수립하고 정보를 추출해 비즈니스 인텔리전스(Business Intelligence)나 예측 분석 등의 분석 작업을 주로 수행함

- 텍스트 분류(Text Classification)
 - Text Categorization
 - 문서가 특정 분류 또는 카테고리에 속하는 것을 예측하는 기법
 - 예.
 - 특정 신문 기사 내용이 어떤 카테고리에 속하는지 자동으로 분류
 - 스팸 메일 검출
 - 지도 학습 적용
- 감성 분석(Sentiment Analysis)
 - 텍스트에서 나타나는 감정/판단/믿음/의견/기분 등의 주관적인 요소를 분석하는 기법의 총칭
 - 예.
 - 소셜 미디어 감정 분석
 - 영화나 제품에 대한 긍정 또는 리뷰
 - 여론 조사 의견 분석 등
 - 지도/비지도 학습을 이용해 적용
- 텍스트 요약(Summarization)
 - 텍스트 내에서 중요한 주제나 중심 사상을 추출하는 기법
 - 토픽 모델링(Topic Modeling)
- 텍스트 군집화와 유사도 측정
 - 텍스트 군집화
 - 비슷한 유형의 문서에 대해 군집화를 수행하는 기법
 - 텍스트 분류를 비지도학습으로 수행하는 방법의 일환
 - 유사도 측정
 - 문서들간의 유사도를 측정해 비슷한 문서끼리 모을 수 있는 방법

4. 텍스트 분석 수행 프로세스



1단계. 텍스트 사전 준비 작업(텍스트 전처리)

텍스트를 피쳐(feature)로 만들기 전에 텍스트 정규화 작업을 수행하는 것을 통칭

- 대소문자 변경, 특수문자 삭제 등의 클렌징
- 단어 토큰화
- 의미없는 단어(Stop word:불용어) 제거
- 어간 추출(Stemming/Lemmatization)
- 정규화(normalization)

2단계. 피쳐 벡터화(Feature Vectorization)


- 사전 준비 작업으로 가공된 텍스트에서 피쳐를 추출하고 여기에 벡터 값을 할당
- 피쳐 추출(feature extration)이라고도 함
- 텍스트를 word(또는 word의 일부분) 기반의 다수의 피쳐로 추출하고 이 피쳐에 단어 빈도수와 같은 숫자 값을 부여하여 단어의 조합인 벡터값으로 표현하는 것
- 피쳐 벡터화 방법
 - BOW(Bag of Words)
 - Count 기반 벡터화
 - TF-IDF 기반 벡터화
 - Word2Vec

3단계. ML 모델 수립 및 학습/예측/평가

피쳐 벡터화된 데이터 세트에 ML 모델을 적용해 학습/예측 및 평가를 수행

피쳐 벡터화

- 텍스트 분석은 비정형 텍스트를 분석하는 것
- 텍스트를 머신러닝에 적용하기 위해서 비정형 텍스트 데이터를 어떻게 피쳐 형태로 추출하고 추출된 피쳐에 의미있는 값을 부여하는가가 매우 중요한 요소



5. 파이썬 기반의 NLP, 텍스트 분석 패키지

: NLP와 텍스트분석을 쉽고 편하게 하기 위한 라이브러리들

- 텍스트 사전 정제 작업, 피쳐 벡터화/추출, ML 모델 지원 등

1) 영어기반 라이브러리

- NLTK(Natural Language Toolkit for Python)
 - 파이썬의 가장 대표적인 NLP 패키지(<https://www.nltk.org/>)
 - 방대한 데이터 세트와 서브 모듈
 - NLP의 거의 모든 영역을 커버
 - 많은 NLP 패키지들이 NLTK의 영향을 받아 작성되고 있음
 - 수행 속도 측면에서 아쉬움
 - 주요 기능 : 말뭉치, 토큰 생성, 형태소 분석, 품사 태깅
 - <https://www.nltk.org/book/>
- Gensim
 - 토픽 모델링 분야에서 가장 두각을 나타내는 패키지
 - Word2Vec 구현
 - SpaCy 와 함께 가장 많이 사용되는 NLP 패키지
- SpaCy
 - 뛰어난 수행 성능으로 최근 가장 주목을 받는 NLP 패키지
 - 실제 업무에서 자주 활용됨

2) 한글 기반 라이브러리

- KoNLPy(코엔엘파이)
 - 한국어 처리를 위한 파이썬 라이브러리
 - <https://konlpy.org/ko/latest/index.html>
 - 오픈소스 형태소 분석기
 - 꼬꼬마(Kkma), 코모란(Komorán), 한나눔(Hannanum), 트위터(Twitter), 메카브(Mecab) 분석기 제공


3) 사이킷런(Scikit_Learn)의 머신러닝 알고리즘

- NLP를 위한 어근 처리와 같은 다양한 라이브러리는 가지고 있지 않음
- 텍스트를 일정 수준으로 가공하고 머신러닝 알고리즘에 텍스트 데이터를 피쳐로 처리하기 위한 편리한 기능 제공
- 텍스트 분석 기능은 충분히 수행 가능
- 주요 기능
 - CountVectorizer : 텍스트에서 단어의 등장 횟수를 기준으로 특성 추출
 - Tfidfvectorizer : TF-IDF 값을 이용해서 텍스트의 특성 추출
 - HashingVectorizer : CountVectorizer의 방법과 동일하나 텍스트 처리시 해시 함수를 사용하여 실행시간이 감소됨

6. 관련 용어들

말뭉치(corpus: 코퍼스)

- 자연어 처리에서 모델을 학습시키기 위한 데이터
- 자연어 연구를 위해 특정한 목적에서 표본을 추출한 집합



토큰(token)

- 문서를 나누는 단위
- 문자열을 토큰으로 나누는 작업을 토큰 생성(tokenizing)이라고 함
- 문자열을 토큰으로 분리하는 함수를 토큰 생성 함수라고 부름

토큰화(tokenization)


- 텍스트를 문장이나 단어로 분리하는 것
- 토큰화 단계를 마치면 텍스트가 단어 단위로 분리됨

불용어(stop words)

- 문장 내에서 많이 등장하는 단어로 분석과 관계없으며 자주 등장하는 빈도로 성능에 영향을 미치는 단어들
- 사전에 제거해 주어야 함
- 예. 'a', 'the', 'she', 'he'

어간 추출(stemming)

- 단어를 기본 형태로 만드는 작업
- 예. 'consign', 'consigned', 'consigning', 'consignment' 등을 기본 단어인 'consign'으로 통일



품사 태깅(part-of-speech tagging)

- 주어진 문장에서 품사를 식별하기 위해 붙여주는 태그(식별 정보)
- 영어 품사의 예.
 - Det : 한정사
 - Noun : 명사
 - Verb : 동사
 - Prep : 전치사

